

UTAMED
UNIVERSIDAD

UNIVERSIDAD TECNOLÓGICA ATLÁNTICO-MEDITERRÁNEO

Máster Universitario en Inteligencia Artificial

MOTOR PREDICTIVO RESULTADOS DE FÚTBOL

Trabajo fin de estudio presentado por:	VALME
Especialidades del TFE	MACHINE LEARNING
Director/a:	XXXXX
Fecha:	Junio 2026

Resumen

Este Trabajo de Fin de Máster aborda el problema de la predicción de resultados en fútbol mediante el uso de técnicas de aprendizaje automático aplicadas a datos históricos en abierto. El objetivo general es crear un motor predictivo capaz de clasificar el resultado de un partido de la liga de fútbol española en victoria local, empate o victoria visitante.

Para ello, se emplea el conjunto de datos *European Soccer Database* (Mathien, 2017), filtrado para la liga de fútbol española (LaLiga, 2026) en el periodo 2008–2016. A partir de esta información, se construye un conjunto de variables históricas prepartido basadas en el rendimiento previo de los equipos, incluyendo métricas de estado de forma, rendimiento acumulado y contexto de temporada, garantizando la consistencia temporal de los datos tal y como recogen Al-Bustami y Ghazal (2025).

Desde el punto de vista metodológico, se plantea la comparación entre un modelo base de regresión logística multinomial, tres versiones del modelo *Random Forest* y un modelo *XGBoost* con el fin de evaluar el modelo que aporta una mayor capacidad predictiva (Rodrigues y Pinto, 2022).

Como aportación complementaria, se plantea de forma teórica el uso de visualización táctica interactiva para facilitar la interpretación de los resultados y su aplicación en entornos profesionales, tal y como recomienda De la Vega et al. (2008).

Palabras clave:

Predicción de resultados en fútbol, *Machine Learning*, Analítica deportiva, Datos abiertos, Modelos predictivos

Abstract

This Master's Thesis addresses the problem of football match outcome prediction using machine learning techniques applied to open historical data. The main objective is to develop a predictive engine capable of classifying the outcome of a Spanish football league match into home win, draw, or away win.

To this end, the European Soccer Database (Mathien, 2017) is used, filtered for the Spanish football league (LaLiga, 2026) over the 2008–2016 period. Based on this information, a set of pre-match historical variables is constructed from teams' prior performance, including metrics of form, cumulative performance, and seasonal context, ensuring the temporal consistency of the data as outlined by Al-Bustami and Ghazal (2025).

From a methodological perspective, a comparison is proposed between a baseline multinomial logistic regression model, three versions of the Random Forest model, and an XGBoost model in order to evaluate which model provides the greatest predictive capability (Rodrigues and Pinto, 2022).

As a complementary contribution, the theoretical use of interactive tactical visualization is proposed to facilitate the interpretation of results and their application in professional environments, as recommended by De la Vega et al. (2008).

Keywords:

Football result prediction, Machine Learning, sports analytics, open data, predictive models

ÍNDICE DE CONTENIDOS

1. Justificación 8

2. Introducción 10

3. Objetivos 15

3.1. Objetivo general 15

3.2. Objetivos específicos 15

4. Metodología empleada 16

4.1. Descripción de la metodología 16

4.2. Justificación de la metodología empleada 18

5. Desarrollo del trabajo en función de su temática 20

5.1. Estado del arte 20

5.1.1. Enfoques clásicos de predicción en fútbol 20

5.1.2. Aplicación de técnicas de Machine Learning en el fútbol 22

5.1.3. Datos abiertos en la industria del fútbol 24

5.1.4. Limitaciones y retos en la predicción de resultados de fútbol 25

5.1.5. Perspectiva profesional sobre el uso de datos en clubes de fútbol 26

5.2. Desarrollo del trabajo en función de su temática 28

5.2.1. Obtención de la base de datos 28

5.2.2. Preparación del conjunto de datos y construcción de variables predictoras 29

Preparación y procesamiento del conjunto de datos 29

Definición de la variable objetivo 30

Construcción de variables históricas prepartido 30

Criterios de exclusión de partidos 32

Selección final de variables predictoras 33

División del conjunto de datos 33
5.2.3. Modelos predictivos empleados 34
Regresión logística multinomial 34
Random Forest 35
XGBoost 36
5.2.4. Métricas de evaluación 37
5.2.5. Resultados experimentales 40
Resultados en el conjunto de validación 40
Selección del modelo final 43
Resultados en el conjunto de test 44
Análisis de los resultados 46
5.3. Propuesta teórica de una herramienta de visualización táctica interactiva 48
5.3.1. Justificación de la visualización de los datos en el fútbol 49
5.3.2. Objetivos de la herramienta propuesta 53
5.3.3. Diseño conceptual de la herramienta 53
6. Conclusiones 60
6.1. Cumplimiento de los objetivos 60
6.2. Reflexión y aportaciones 62
6.3. Autocrítica y limitaciones 63
6.4. Futuras líneas de investigación 64
7. Referencias bibliográficas 67

ÍNDICE DE FIGURAS

Figura 1. “Métricas por clase - Random Forest balanced (test)”. (Elaboración propia) 44

Figura 2. “Matriz de confusión - Random Forest balanced (test)”. (Elaboración propia) 45

Figura 3. “Mapa de calor de Martin Odegaard”. (Carpio, G) 52

Figura 4. “Panel de navegación”. (Elaboración propia) 55

Figura 5. “Panel de información”. (Elaboración propia) 56

Figura 6. “Panel predictivo”. (Elaboración propia) 57

Figura 7. “Panel táctico y espacial”. (Elaboración propia) 58

ÍNDICE DE TABLAS

Tabla 1. Resultados experimentales de Accuracy y Macro F1-score de los diferentes modelos en el conjunto de validación 41

Tabla 2. Resultados experimentales de F1 Score a nivel de etiqueta de los diferentes modelos en el conjunto de validación 42

Tabla 3. Resumen de mejores configuraciones por objetivo 48

1. Justificación

En los últimos años, el análisis de datos ha adquirido especial relevancia dentro de la industria del fútbol. Tal y como se desarrolla posteriormente en el estado del arte del presente trabajo, el uso de técnicas de *Machine Learning* en el mundo del fútbol ha experimentado un gran crecimiento en el ámbito académico y profesional.

Actualmente, el fútbol genera enormes volúmenes de información relacionados con el rendimiento de equipos, incluyendo resultados históricos, eventos detallados del partido y variables tácticas. La ciencia de datos es una disciplina fundamental para transformar estos datos en conocimiento útil para entrenadores y analistas.

La relevancia del presente Trabajo de Fin de Máster (TFM) se justifica por la necesidad de presentar metodologías capaces de predecir resultados de fútbol mediante datos abiertos. Además, se propone un enfoque diferencial frente a otros proyectos centrados exclusivamente en los resultados de los modelos de *Machine Learning*, al combinar la construcción de variables históricas prepartido, la comparación de distintos modelos de clasificación supervisada y el planteamiento conceptual de herramientas de visualización tácticas interactivas para convertir los datos en conocimiento útil para perfiles no técnicos.

Además, el trabajo tiene una complejidad inherente del problema estudiado dado el alto grado de incertidumbre en los resultados de fútbol, siendo el empate el resultado más difícil de predecir. De esta forma se puede evaluar el rendimiento de distintos modelos y analizar sus limitaciones reales.

Otro aspecto importante es el uso de datos abiertos y tecnologías accesibles para llevar a cabo la investigación. El proyecto utiliza datos del *European Soccer Database*, un conjunto de datos público de resultados de fútbol entre las temporadas 2008-2016, y se desarrolla en el ecosistema de *Python*.

Por último, los resultados obtenidos pueden servir como base para futuras aplicaciones en la industria y futuras líneas de investigación relevantes. El modelo desarrollado permite identificar patrones históricos en el rendimiento de los equipos gracias a información previa a los partidos, así como el planteamiento de herramientas de visualización para profesionales del fútbol aporta una dimensión adicional a este proyecto.

2. Introducción

El fútbol es considerado como uno de los deportes más populares del mundo. En él, dos equipos de once jugadores se enfrentan entre sí en un partido que cuenta con dos tiempos de 45 minutos. Vence aquel que es capaz de introducir un mayor número de veces el balón en la portería contraria empleando para ello cualquier parte de su cuerpo (cabeza, piernas, pies, hombros, pecho) con la excepción de las manos.

El origen de este deporte se remonta a la antigua China. Otras culturas como la Maya, contaban con un deporte semejante. La versión moderna de este deporte surge en Inglaterra en torno al año 1863 en el que la *Football Association* (thefa, 2026), organismo rector inglés, recopila y codifica el primer reglamento con las leyes que lo rigen.

En 1904 se funda la FIFA (Fédération Internationale de Football Association) organismo mundial rector del fútbol y sus variantes (fútbol sala, fútbol playa). Con sede en Suiza, su función principal es la de adaptar la normativa y organizar, cada cuatro años, la Copa Mundial de Fútbol.

En 1954 se funda la UEFA (Union des Associations Européennes de Football) organismo rector, administrativo y de control del fútbol en Europa que agrupa a cincuenta y cinco federaciones nacionales.

Otras instituciones semejantes como la CONMEBOL (Confederación Sudamericana de Fútbol), la CONCACAF (Confederación de Norteamérica, Centroamérica y el Caribe de Fútbol), la CAF (Confederación Africana de Fútbol), la AFC (Confederación Asiática de Fútbol) y la OFC (Confederación de Fútbol de Oceanía), realizan funciones semejantes a las de la UEFA y todas ellas, cada cuatro años, coincidiendo entre dos períodos mundialistas, organizan la correspondiente edición del Campeonato de Selecciones.

Las cifras de seguimiento de este deporte son inmensas, de hecho, la FIFA indicó que más de 5000 millones de personas visionaron, en parte o en su totalidad, alguno de los encuentros de la fase final del Mundial de Qatar (FIFA publications, 2022), celebrado en 2022 y que aproximadamente 500 millones de espectadores vieron la final de la Champions League, en la que se enfrentan los finalistas de la fase de grupos de la UEFA.

Ante este panorama, se puede afirmar que estamos ante una de las industrias del deporte más importantes, que trasciende fronteras, cultura y niveles sociales y económicos y que genera cifras desorbitadas en lo que a movimientos económicos se refiere.

Esta dinámica conlleva a preguntarnos si seríamos capaces de predecir el resultado de un partido.

En este sentido, la teoría de juegos (Oliver, 2021), sección de la estadística que analiza qué y qué no puede o debe considerarse un juego, establece que el fútbol es un juego ya que cumple con los requisitos de ser una situación donde la estrategia actúa condicionando el resultado final, siendo este dependiente no de las acciones del equipo, sino también de las decisiones que el contrario puede adoptar.

Considerando todo esto, y basándonos en la teoría de juegos, debemos entender que el choque (encuentro) es un conflicto de estrategia, donde las decisiones que adopta el equipo como atacante, defensa o formación, van a ser dependientes de las que adopte el equipo contrario. Esto provoca lo que se conoce como equilibrio de Nash. Esto se debe, en contraposición a la estadística pura, a que el enfoque adoptado, asume que ambos contendientes actúan de modo racional con el fin de maximizar sus propios beneficios con el fin de obtener la victoria ante el rival, que actúa en consecuencia para obtener el mismo resultado (Keskin, 2025).

Predecir el resultado de un partido no se limita únicamente al ámbito de las apuestas deportivas, sino que tiene relevancia en otras dimensiones en el contexto profesional. Entre ellas destacan la planificación táctica de los entrenadores de los equipos implicados, el análisis comparativo entre equipos, la evaluación del rendimiento y el apoyo en la toma de decisiones estratégicas.

El fútbol, como deporte en el que interviene directamente el factor humano, posee un comportamiento estocástico. El resultado puede verse influenciado por múltiples factores estructurales y aleatorios. Entre ellos se encuentran la calidad competitiva, el estado de forma de los jugadores, la ventaja táctica de jugar como local, la dinámica global de la temporada, la dinámica histórica del club, la eficacia ofensiva y defensiva, o la posición en la clasificación.

No obstante, existen otros elementos difícilmente observables como las lesiones, las decisiones arbitrales, la presión psicológica o determinadas acciones puntuales que pueden alterar el resultado del juego. Esta combinación de factores observables y no medibles ha provocado que la predicción de resultados en el fútbol haya sido objeto continuo de estudio durante décadas.

El interés por abordar este problema se remonta a la segunda mitad del siglo XX (años 50-80) donde comenzaron a desarrollarse los primeros modelos estadísticos aplicados al fútbol. Entre ellos destacan aquellos basados en distribuciones de Poisson para modelar goles a partir de resultados históricos con el objetivo de que el fútbol no era sólo azar y podía predecirse con datos.

Posteriormente, en los años 1990-2000, surgieron los modelos de *rating* como el sistema Elo adaptado al fútbol, así como enfoques bayesianos orientados a actualizar las fuerzas ofensivas y defensivas de los equipos, que es la base de muchos sistemas aún en uso.

A partir del año 2010, el desarrollo tecnológico y el incremento de la disponibilidad de datos han impulsado una nueva etapa en la analítica

deportiva. El fútbol profesional ha incorporado de forma progresiva el uso de datos para apoyar decisiones deportivas. En paralelo, desde el ámbito académico, diversos estudios han explorado el uso de modelos estadísticos y técnicas de aprendizaje automático para analizar el rendimiento de los equipos y predecir resultados deportivos (Constantinou & Fenton, 2013).

Varios estudios como *Predicting Football Match Outcomes Using Event Data and Machine Learning Algorithms* o *SoccerNet: A Gated Recurrent Unit-based model to predict soccer match winners* demuestran que modelos como Random Forest predicen resultados usando indicadores técnicos con buena precisión.

Además, se ha producido un aumento de la disponibilidad de datos abiertos. Esto ha facilitado el acceso a información que anteriormente estaba reservada a clubes o empresas especializadas, favoreciendo así el surgimiento de proyectos académicos de la industria del fútbol. Entre estos recursos destaca el *dataset StatsBomb Open Data*, cuyo objetivo es facilitar el acceso a datos de eventos de fútbol para investigación y aprendizaje, así como bases de datos históricas como *European Soccer Database*, disponible en Kaggle, que incluye información de partidos, equipos y otras variables en temporadas europeas desde 2008 hasta 2016.

El uso de datos históricos de competiciones oficiales y el *Machine Learning* se presenta como una herramienta adecuada para abordar el problema de la predicción del resultado de un partido previo a su comienzo. El presente TFM se apoya principalmente en el *dataset European Soccer Database*, a partir del cual se construirá un conjunto de variables prepartido que reflejen el rendimiento histórico de los equipos.

Sobre esta base, se propone el desarrollo de un motor predictivo prepartido centrado en LaLiga española en el que se compararán distintos enfoques metodológicos. En particular, se evaluará el rendimiento de un modelo de

regresión logística multinomial frente a modelos de *Machine Learning* basados en árboles de decisión (*Random Forest* y *XGBoost*) tal y como recogen Rodrigues y Pinto en su estudio (2022). Este enfoque permitirá analizar la capacidad de los modelos no lineales de capturar relaciones complejas en los datos, así como comparar sus resultados con los obtenidos con un modelo interpretable.

Finalmente, como línea complementaria, se plantea la integración de estos modelos predictivos en herramientas de visualización táctica interactiva aplicadas al análisis de datos en fútbol. Estas herramientas permiten interpretar patrones de forma intuitiva y facilitan la comprensión de datos y predicciones técnicas a usuarios no técnicos como entrenadores, ojeadores y público especializado.

3. Objetivos

A. Objetivo general

Como objetivo general, el presente trabajo plantea:

Crear un motor predictivo de resultados basado en los partidos de la liga de fútbol española.

B. Objetivos específicos

En cuanto a los objetivos específicos que emanan del objetivo general, el trabajo aborda los siguientes:

Analizar las técnicas utilizadas actualmente en predicción de resultados en la industria del fútbol.

Identificar patrones complejos históricos para modelar el rendimiento de los equipos y la predicción de resultados.

Desarrollar un conjunto de datos estructurado basado en el *European Soccer Database* filtrado por LaLiga española, incorporando variables predictoras basadas en el rendimiento histórico de los equipos previo al partido.

Implementar y comparar la capacidad predictiva de distintos modelos de clasificación (regresión logística multinomial, *Random Forest* y *XGBoost*).

Plantear la implementación de herramientas de visualización táctica interactiva para comunicar patrones de juego y resultados a cuerpo técnico y ojeadores.

4. METODOLOGÍA EMPLEADA

El presente TFM emplea una metodología empírica cuantitativa basada en análisis de datos y *Machine Learning*.

A. DESCRIPCIÓN DE LA METODOLOGÍA

La metodología empleada en el mismo se basa en un enfoque propio de la ciencia de datos aplicada al deporte con el objetivo de desarrollar y evaluar modelos predictivos capaces de estimar los resultados de partidos a partir de información histórica previa al encuentro, logrando así identificar patrones complejos en el rendimiento de los equipos.

El proceso metodológico se estructura en varias fases:

1) Revisión del estado del arte: se analizan investigaciones previas y actuales sobre predicción de resultados en la industria del fútbol, de manera que se pueda identificar enfoques metodológicos y variables relevantes utilizadas.
2) Selección y obtención de datos: se emplea el conjunto de datos *European Soccer Database*, que contiene información histórica de competiciones europeas desde 2008 hasta 2016. A partir de este *dataset*, se seleccionarán únicamente aquellos partidos correspondientes a LaLiga española.
3) Limpieza y preparación del conjunto de datos: se realiza un proceso de limpieza y estructuración de los datos mediante *Python*, incluyendo la conversión de variables temporales, la selección de columnas relevantes para el análisis y la integración de diferentes tablas del *dataset*.
4) Ingeniería de variables: se lleva a cabo la construcción de variables explicativas basadas exclusivamente en información disponible antes de cada partido, garantizando la consistencia temporal del modelo.

Para ello, se genera un *dataset* intermedio con una observación por equipo y partido (dos registros por encuentro), lo cual permite calcular métricas históricas sin utilizar información futura. Las variables construidas se agrupan en los siguientes bloques principales:

- Variables del rendimiento reciente: se calculan métricas sobre los últimos cinco partidos de cada equipo dentro de la misma temporada para capturar el estado de forma reciente del equipo.
- Variables acumuladas históricas: se construyen indicadores agregados desde el inicio del histórico hasta el partido anterior para reflejar el rendimiento global del equipo.
- Variables específicas por condición local/visitante: se calculan métricas para captar la influencia del factor campo como el rendimiento del equipo local en casa y el del equipo visitante fuera de casa.
- Variables de contexto de temporada: se calculan métricas específicas de dicha temporada como los puntos acumulados hasta entonces.

5) Definición de la variable objetivo: la variable objetivo se trata de una variable categórica con tres posibles valores: victoria local (*HomeWin*), empate (*Draw*) y victoria visitante (*AwayWin*), en función el resultado final del partido.
6) División temporal del conjunto de datos: el *dataset* se divide de forma temporal para simular un escenario real de predicción:

- Entrenamiento: temporadas 2008-2013.
- Validación: temporadas 2014-2015.
- Test: temporada 2015-2016

7) Desarrollo y comparación de modelos predictivos: se implementan y comparas diferentes modelos:

- Regresión logística multinomial
- *Random Forest*

- *XGBoost*

  Además, se exploran variantes con regularización y ponderación de clases.

8) Evaluación de los modelos: el rendimiento de los modelos se evalúa con las siguientes métricas de clasificación:

- Macro *F1-score*: media del *F1-score* por clase para evaluar el rendimiento de forma equilibrada, ya que se trata de un problema con el *dataset* desbalanceado.
- *F1-score* por clase: para analizar el comportamiento específico en cada resultado.
- Matriz de confusión: para evaluar los fallos y aciertos en las predicciones de los modelos.

9) Visualización e interpretación de resultados: se generan representaciones visuales de las métricas anteriores para analizar el comportamiento de los modelos y facilitar la interpretación de los mismos.

10) Planteamiento de herramientas de visualización interactiva que sean útiles para interpretar y comunicar los resultados predictivos a miembros del cuerpo técnico y del equipo de ojeadores en la industria del fútbol.

b. Justificación de la metodología empleada

La metodología empleada se basa en un enfoque empírico cuantitativo apoyada en técnicas de ciencia de datos y *Machine Learning*, pues es la más adecuada para analizar fenómenos complejos (como es la predicción de resultados de un partido de fútbol) a partir de grandes volúmenes de datos. Las bases de datos históricas de las que disponen los equipos de fútbol profesionales permiten aplicar modelos predictivos capaces de identificar patrones complejos en el rendimiento de los equipos y predecir el resultado.

Usar modelos de clasificación supervisada se justifica dado que el caso de uso se formula como un problema de clasificación multiclase (victoria local, empate o derrota local).

La regresión logística multinomial es el modelo base dado su simplicidad e interpretabilidad, mientras que la incorporación de modelos de *Machine Learning* permite explorar las relaciones no lineales entre variables que mejoran el rendimiento predictivo frente a los modelos estadísticos tradicionales.

La decisión de dividir el conjunto de datos de forma temporal se debe a que es necesario simular un escenario de predicción sobre partidos futuros, por lo que no podemos dividir de forma aleatoria sino basado en una división temporal.

Por último, la inclusión del planteamiento de herramientas de visualización táctica interactiva es fundamental para comunicar los resultados del análisis a los actores principales de la industria del fútbol.

5. Desarrollo del trabajo en función de su temática

En este apartado se desarrolla el núcleo principal del TFM, el cual se estructura en diferentes bloques que abordan el problema de forma progresiva. En primer lugar, se recoge una revisión del estado del arte donde se analizan técnicas empleadas en la predicción de resultados de fútbol. Después, se explica y desarrolla el proceso de obtención, preparación y transformación de datos para llevar a cabo la comparativa entre los diferentes modelos predictivos. Por último, se evalúa el rendimiento de los modelos y se extraen conclusiones del estudio realizado.

5.1. Estado del arte

Esta revisión del estado del arte permite contextualizar el problema de la predicción de resultados de fútbol en el ámbito académico y profesional. Así, se revisa la evolución de los principales enfoques utilizados comenzando por los modelos estadísticos tradicionales hasta llegar a las técnicas actuales de aprendizaje automático.

5.1.1. Enfoques clásicos de predicción en fútbol

Los primeros enfoques orientados a la predicción de resultados en el fútbol se basaban en modelos estadísticos tradicionales cuyo objetivo era estimar la probabilidad de los distintos resultados posibles mediante información histórica del rendimiento de los equipos.

Entre los enfoques más relevantes destacan aquellos basados en distribuciones de probabilidad, especialmente los modelos de Poisson, que permitían estimar el número esperado de goles que cada equipo puede marcar en un partido. En este contexto, Maher (1982) propuso uno de los primeros modelos aplicados al fútbol, en el que los goles anotados por cada equipo se modelizan como variables aleatorias independientes que seguían una distribución de Poisson. En

dicho modelo, la media de la distribución depende de parámetros asociados a los rendimientos ofensivo y defensivo de los equipos, así como la ventaja de jugar como local.

No obstante, este modelo presenta algunas limitaciones, pues el marcador en un partido de fútbol puede ser muy ajustado, de manera que, si un equipo muy fuerte tiene dos goles esperados y otro muy débil tiene un gol esperado, existe una probabilidad razonable de que gane cualquiera de los dos.

Para superar algunas de estas limitaciones, surgieron modelos de *rating*, entre los que destaca el sistema ELO. El modelo ELO es una de las herramientas estadísticas más utilizadas en el mundo del fútbol, cuyo objetivo es asignar a cada equipo una puntuación numérica que represente su nivel competitivo actual. Esta puntuación se modifica después de cada partido dependiendo del resultado y de las expectativas previas, por lo que ganar a un rival fuerte no tiene el mismo impacto numérico que a un rival débil.

También han surgido modelos aplicados en el ámbito del periodismo de datos, como el FiveThirtyEight que asigna a cada equipo una puntuación mediante el índice SPI (*Soccer Power Index*). El SPI, creado por Nate Silver en 2009 (creador de FiveThirtyEight), se interpreta como el resultado esperado de un equipo frente a un rival medio, descomponiéndose en un componente ofensivo (capacidad de marcar goles, se quiere que sea alto) y otro defensivo (capacidad de evitar goles, se pretende que sea bajo). Después de cada partido estos valores se actualizan dependiendo del rendimiento y la fuerza del rival. De hecho, si un equipo gana, pero lo hace por menos de lo esperado, el *rating* disminuye.

Algunas grandes compañías tecnológicas como Google o Microsoft han desarrollado sus propios modelos predictivos aplicados al fútbol. Entre ellas destaca el caso de Microsoft, cuyo buscador Bing utiliza modelos de matemáticas predictivas combinando datos de los dos equipos (resultados

previos, equipo local, meteorología, márgenes de victoria) con datos de la percepción de los aficionados (consultas de los aficionados por búsquedas en Bing y redes sociales). El modelo asigna a cada equipo un porcentaje de probabilidad de victoria, empate o derrota y, tal y como indica Microsoft en su web, en el Mundial de Brasil de 2014 su algoritmo acertó el pronóstico en 15 de los 16 partidos de la fase de grupos.

Google ha desarrollado su modelo predictivo de partidos de fútbol basado en técnicas como la regresión logística. Este modelo se creó para las fases finales del Mundial de 2014 y no considera la posibilidad de empate. Se basa en la fase de grupos (tres partidos previos) para estimar las probabilidades de cada equipo de pasar a la siguiente ronda.

5.1.2. Aplicación de técnicas de Machine Learning en el fútbol

En los últimos años, la predicción de resultados en el fútbol ha experimentado un gran avance gracias a las técnicas de aprendizaje automático. Estas técnicas permiten modelizar relaciones complejas entre múltiples variables y superar algunas de las limitaciones de los modelos estadísticos tradicionales.

En el ámbito académico, diversos estudios han demostrado la viabilidad de aplicar algoritmos supervisados para la predicción de resultados. El estudio *Predicting Football Match Outcomes using Event Data and Machine Learning Algorithms* demuestra que es posible predecir los resultados de la temporada 2015/16 en las cinco principales ligas europeas mediante el *dataset StatsBomb* y modelos supervisados llegando a alcanzar un 90% de acierto en la última jornada de LaLiga gracias a la incorporación de información acumulada.

Otra línea de investigación se centra en el análisis de variables de rendimiento sobre el resultado de los partidos. En este sentido, el estudio *Construction of*

2022 Qatar World Cup match result prediction model and analysis of performance indicators analiza la influencia de las métricas de rendimiento en los resultados de los partidos en el Mundial de Qatar de 2022 mediante la aplicación de distintos algoritmos de aprendizaje automático entre los que se incluyen árboles de decisión, regresión logística, máquinas de vectores de soporte, *AdaBoost*, bosques aleatorios y redes neuronales artificiales.

Además, se han desarrollado modelos basados en redes neuronales para abordar esta problemática. El estudio SoccerNet *A Gated Recurrent Unit-based model to predict soccer match winners* propone un modelo GRU para predecir el ganador de cada partido y validar que el rendimiento físico y técnico de los jugadores se relaciona con la probabilidad de victoria mediante datos de la Qatar Stars League de 10 temporadas.

Más recientemente, la investigación titulada *Toward interpretable expected goals modeling using Bayesian mixed models* introduce un enfoque basado en modelos lineales generalizados bayesianos de efectos mixtos para la estimación de goles esperados (xG). Dicho modelo tuvo un rendimiento similar al modelo *StatsBomb* usando tan sólo siete variables.

De forma paralela al desarrollo académico, el uso de datos y modelos predictivos ha adquirido una fuerte relevancia en el fútbol profesional. El *Big Data* se ha consolidado como una herramienta fundamental en los clubes profesionales. De hecho, proveedores de datos de fútbol, como Sportmonks, señalan que los entrenadores usan *Big Data* para preparar los partidos frente a sus adversarios y optimizar el rendimiento de sus jugadores, así como los ojeadores lo utilizan para mejorar la exploración y el reclutamiento de nuevos talentos.

Un caso representativo de la aplicación de modelos basados en datos es el Brentford, equipo de la Premier League. Este club ha adoptado un enfoque

innovador centrado en el análisis de datos para tomar decisiones deportivas, especialmente en el ámbito de reclutamiento de jugadores. En 2016 modificaron su estructura formativa, priorizando la captación de talento basada en datos frente al modelo tradicional de cantera. Este enfoque ha sido asociado al éxito deportivo del club, ya que logró volver a la Premier League más de 70 años después.

No obstante, a pesar de su creciente importancia, los clubes profesionales suelen ser reticentes a divulgar información detallada sobre sus modelos internos. Aun así, se considera que se utilizan modelos similares a los desarrollados por la literatura científica en las diferentes áreas deportivas (*scouting*, prevención de lesiones, decisiones tácticas).

5.1.3. Datos abiertos en la industria del fútbol

El desarrollo de investigaciones científicas y académicas en analítica deportiva ha sido posible gracias al crecimiento de la disponibilidad de datos en abierto relacionados con competiciones deportivas. Tradicionalmente, esta información estaba reservada a los clubes y empresas especializadas, limitando así el acceso a investigadores y analistas independientes.

No obstante, en los últimos años se ha producido un incremento significativo en la disponibilidad de repositorios públicos con datos de resultados, análisis de rendimientos de equipos y jugadores, así como variables asociadas al desarrollo de los partidos.

Entre los conjuntos de datos más relevantes destaca el *European Soccer Database*, que se usará en este TFM. Esta base de datos recoge información histórica de las principales ligas europeas entre 2008 y 2016, incluyendo más de 25.000 partidos, más de 10.000 jugadores, variables de equipos y jugadores; cuotas de apuestas e información de los eventos del partido (tipos de gol, posesión, córneres, tarjetas).

Otro recurso de especial interés es *StatsBomb Open Data* que se compone de datos de eventos detallados del partido y patrones tácticos. Entre ellos podemos encontrar datos sobre pases, alineaciones, goles esperados, tiros, recuperaciones de balón...

También existen otras plataformas como la web Football-Data, que proporciona resultados históricos de fútbol, datos de cuotas de apuestas y estadísticas de partidos de forma gratuita desde julio de 2007. Otra web muy interesante es FBREF donde se pueden encontrar estadísticas, puntuaciones e historia de jugadores de clubes, así como de los clubes de fútbol profesionales.

Este crecimiento de repositorios de *datasets* abiertos ha permitido el crecimiento de investigaciones académicas e independientes en el ámbito de la analítica de fútbol, ya que la disponibilidad de datos consolidados es fundamental para el desarrollo e investigación de modelos analíticos.

5.1.4. Limitaciones y retos en la predicción de resultados de fútbol

A pesar de los avances en la predicción en resultados de fútbol, desde los primeros modelos estadísticos tradicionales hasta los modelos más complejos de aprendizaje automático que se utilizan hoy en día, este problema continúa presentando importantes limitaciones y desafíos. Esto se debe principalmente a la naturaleza del propio deporte, caracterizada por un alto grado de incertidumbre y variabilidad en los resultados.

Uno de los principales factores de esta variabilidad es el reducido número de goles que se producen en un resultado de fútbol. En este sentido, Mark Dixon y Stuart Coles (1997), en su estudio titulado *Modelling Association Football Scores and Inefficiencies in the Football Betting Market,* señalan que los modelos ven

limitada su capacidad predictiva por la alta varianza que produce el número reducido de goles.

Además, en el desarrollo de un partido de fútbol influyen otros factores humanos muy relevantes que son impredecibles y difíciles de cuantificar como las lesiones de última hora, las decisiones arbitrales, la presión psicológica o la influencia de la afición local. Estos elementos, junto con el componente de aleatoriedad por la naturaleza del deporte, dificultan la construcción de modelos predictivos precisos.

Finalmente, la predicción de resultados presenta una complejidad adicional al tratarse de un problema de clasificación multiclase. A diferencia de otros deportes en los que el resultado se puede modelar como un problema de clasificación binario, en el fútbol existen tres posibles resultados, obligando al modelo a tener que discriminar entre tres clases con distribuciones que no tienen por qué estar equilibradas.

Por tanto, estas limitaciones manifiestan que la predicción de resultados en el fútbol no se puede abordar solo con una perspectiva determinista, sino que requiere que los modelos predictivos integren información histórica, capacidad de generalización y un adecuado tratamiento de la incertidumbre.

5.1.5. Perspectiva profesional sobre el uso de datos en clubes de fútbol

Con el objetivo de complementar la revisión bibliográfica con una perspectiva profesional sobre el uso de datos en clubes de fútbol, se realizó una breve entrevista a Rubén Sánchez, analista de datos del Dos Hermanas CF, y que ha trabajado en diferentes clubes de distintas categorías en el pasado (Real Betis Balompié, Málaga CF y Utrera). Mediante esta entrevista se logró detectar

tendencias y limitaciones en el uso de datos en clubes de fútbol, así como entender la diferencia en dicho uso entre clubes de distintas categorías.

El entrevistado comentó las diferencias significativas en el uso de datos entre clubes de fútbol dependiendo de sus recursos económicos. Los clubes profesionales cuentan con departamentos estructurados y herramientas avanzadas, mientras que los clubes de categorías inferiores trabajan con metodologías mucho más simple. No obstante, cabe destacar que, incluso en categorías más bajas, se intenta extraer información útil de los datos.

En cuanto a las áreas donde se utilizan más los datos son el análisis de partidos y el análisis de rivales, así como está creciendo el uso en *scouting*. En estos aspectos se utilizan indicadores para identificar patrones de rendimiento o detectar jugadores con potencial de rendimiento.

Señaló que el *Machine Learning* y la Inteligencia Artificial es algo que se está implementando poco a poco en todos los clubes profesionales, pero sin ser aún una prioridad, mientras que fuera del fútbol profesional el análisis de datos se limita en interpretar el pasado más que en la predicción. Las áreas donde más cabida tienen estas tecnologías en los clubes profesionales son el análisis del rendimiento físico y la prevención de lesiones, en las cuales se usan sensores y sistemas de seguimiento de los jugadores.

Por último, destacó que las herramientas de visualización y comunicación de los datos que más se utilizan por el cuerpo técnico son los video análisis, los mapas de calor y las comparativas estadísticas, siendo clave que las visualizaciones sean simples y claras. Aunque el ojo clínico sigue siendo relevante en el mundo del fútbol, los entrenadores y personal de *scouting* se apoyan en los datos para la toma de decisiones.

En conclusión, esta perspectiva permite confirmar que el uso de datos y, sobre todo de *Machine Learning* e Inteligencia Artificial para predecir, está aún en fase

de crecimiento, pero que cada vez más los clubes confían en los datos para apoyar su toma de decisiones.

5.2. Desarrollo del trabajo en función de su temática

En este apartado se desarrolla la práctica del trabajo, en la que se implementa la metodología descrita anteriormente con el objetivo de comparar y evaluar el rendimiento de diferentes modelos predictivos en partidos de fútbol. Se explica el proceso llevado a cabo desde la obtención y preparación de los datos hasta la evaluación de los diferentes modelos predictivos desarrollados.

5.2.1. Obtención de la base de datos

Un requisito para llevar a cabo este trabajo es la obtención de una base de datos en abierto accesible y reproducible. Basaremos este TFM en el conjunto de datos *European Soccer Database* publicado en Kaggle por Hugo Mathien. Esta base de datos contiene información histórica de las temporadas 2008 a 2016 de 11 países europeos, con datos de más de 25.000 partidos, más de 10.000 jugadores, datos de cuotas de apuestas de hasta 10 proveedores y otros eventos detallados de partidos. Por tanto, se trata de una fuente adecuada para poder desarrollar modelos predictivos basados en datos históricos en abierto.

Este trabajo centrará su investigación en LaLiga española de manera que el modelo metodológico sea más consistente. La tabla principal será la tabla de los partidos (tabla Match) en la que definiremos la variable objetivo (victoria local, empate o victoria visitante) y sobre la que construiremos las variables explicativas previas al encuentro.

El conjunto de datos se distribuye en formato SQLite, pudiendo consultarlas mediante *Python*. La obtención del *dataset* fue una descarga manual del archivo comprimido desde Kaggle, después se almacenó en Google Drive y se accedió a

ella mediante Google Colab. Se descomprimió el archivo y se trabajó en la creación del *dataframe* consultado la base de datos gracias a la librería sqlite3.

Se desarrolló una fase de exploración de las bases de datos, en la que se identificaron como tablas principales las tablas de Match (tabla principal), Team, League y, de forma complementaria, Team_Attributes. A partir de esta base de datos se desarrollarán tareas de limpieza y transformación hasta la construcción del conjunto de datos final sobre el que se aplicarán los modelos predictivos.

5.2.2. Preparación del conjunto de datos y construcción de variables predictoras

Tras el proceso de integración, transformación y construcción de variables históricas, el conjunto de datos final está compuesto por 2.937 partidos y 56 variables. Este *dataset* será la base analítica del trabajo y recoge información estructural de los partidos, así como características previas al encuentro derivadas del rendimiento histórico de los equipos.

Preparación y procesamiento del conjunto de datos

Tras la obtención del conjunto de datos, se llevó a cabo una fase de preparación y procesamiento para construir un conjunto de datos coherente con el objetivo predictivo. En primer lugar, se llevó a cabo un filtrado de la tabla principal Match combinada con la tabla de League para que sólo salieran los datos de LaLiga española.

La tabla principal es la tabla Match, a la cual se le incorporaron los nombres de los equipos local y visitante (nombres largos y cortos) con una combinación con la tabla de Team mediante el id. Además, se decidieron las columnas de la tabla Match de interés para el estudio. Así, se consiguió una estructura inicial en la que cada fila representa un partido y contiene información del encuentro y de los equipos que disputaron dicho encuentro.

Entre las variables que se conservaron se incluyeron la temporada, la jornada, la fecha del partido, los id de equipos y partido, los nombres largo y corto de los equipos, los goles de cada equipo en ese partido y las cuotas de apuestas prepartido de Bet365 para victoria local, empate o victoria visitante.

Después, se convirtió el tipo de datos de la columna fecha a formato temporal de manera que se pudieran ordenar los partidos de forma cronológica para la construcción posterior de variables históricas.

Definición de la variable objetivo

La variable objetivo o *target* a predecir es victoria local, empate o victoria visitante. De esta manera, el problema es una tarea de clasificación multiclase donde cada partido queda asignado a una única clase según el marcador.

Para crear la variable “result” (es decir, el resultado del encuentro) en nuestro *dataset* se comparó el número de goles del equipo local con el número de goles del equipo visitante. De esta forma, si el número de goles local era superior al visitante, el partido se etiquetó como “HomeWin”; si ambos eran iguales, se clasificó como “Draw”; y si el número de goles local era inferior al número de goles visitantes, se asignó la etiqueta “AwayWin”.

Se observó que la categoría más frecuente fue la victoria local, seguida por la victoria visitante y, en último lugar, el empate, lo que resulta coherente con la ventaja de jugar en casa que suele ser habitual en el fútbol profesional. La victoria local aparecía en el 48,96% de las ocasiones frente al 28,12% de la victoria visitante y el 22,91% del empate la victoria visitante. Esto indica un cierto desbalanceo a tener en cuenta.

Construcción de variables históricas prepartido

Se llevó a cabo la construcción de variables históricas prepartido para poder apoyar nuestro modelo predictivo en información previa a cada encuentro

(Al-Bustami y Ghazal, 2025). Este es uno de los pasos más críticos del trabajo, ya que se convirtió datos en brutos de resultados en indicadores que reflejaban el estado competitivo de los equipos previo a cada partido.

En primer lugar, se construyó un *dataframe* intermedio con una observación por cada equipo, es decir, dos líneas por partido (perspectiva local y perspectiva visitante) para poder construir el historial previo sin usar información posterior de cada encuentro ordenando los datos de forma cronológica. De esta forma, se pudieron calcular métricas acumuladas y recientes de los partidos anteriores, tanto de forma histórica como en el contexto de temporada.

Antes de construir las variables históricas, se generaron una serie de variables básicas previas al partido para poder calcular las métricas históricas: puntos obtenidos del encuentro, variables binarias por victoria, empate o derrota; y diferencia de goles en ese encuentro, calculada como goles marcados menos recibidos.

De esta forma, el primer bloque de variables históricas se trataba de indicadores de los últimos 5 partidos de cada equipo por temporada. Se tomó la decisión de hacerlo por temporada, ya que de una temporada a otra pueden existir muchos cambios en el fútbol como las plantillas, los entrenadores, etc. Entre ellas se incluyeron los puntos y resultados de los últimos cinco partidos, así como la media de goles a favor y en contra de los últimos cinco partidos.

El segundo bloque de variables históricas se trata del histórico acumulado global previo, donde no se reinicia por temporada. Se incluyeron el número de partidos jugados previo y las medias acumuladas de los goles marcados, goles concedidos y puntos obtenidos.

El tercer bloque se constituyó para estudiar el rendimiento histórico del equipo local en casa y del equipo visitante fuera de casa, sin reiniciarlas por temporada. Así, en el caso del local, se calcularon las medias de puntos obtenidos en casa,

de goles concedidos y de goles marcados. De forma equivalente se calcularon para el equipo visitante fuera de casa. Estas variables son importantes, ya que en el fútbol el contexto de jugar en casa tiene mucha relevancia.

También se construyeron variables de contexto de temporada como los puntos acumulados previos en la temporada, la diferencia de goles acumulada previa en la temporada y la posición en la clasificación de cada equipo antes de cada partido.

A partir de estas últimas variables, se construyeron variables de diferencia entre local y visitante como diferencia de puntos, de media de goles anotados, de media de goles concedidos, de puntos de los últimos 5 partidos, de puntos en la temporada, de la posición de la tabla y de la diferencia de goles en la temporada.

La construcción de estas *features* se realizó mediante un criterio temporal donde en cada partido sólo se usaron observaciones anteriores al partido previo y, dado que existían encuentros sin suficiente historial para calculas las variables propuestas, se definió una regla de exclusión para encuentros sin información previa mínima.

Criterios de exclusión de partidos

Para garantizar la coherencia de las variables predictoras construidas, se establecieron criterios de exclusión de partidos dentro del conjunto de datos final, de manera que cada partido tuviera información histórica suficiente y comparable antes del encuentro.

Como los primeros partidos del periodo analizado, así como los primeros partidos de cada temporada no disponían de datos históricos suficientes previos, se excluyeron aquellos en los que las variables históricas no podían calcularse.

De esta forma, el *dataset* final no tiene todos los partidos originales, sino aquellos que cumplen con los requisitos de información histórica previa definida. Tras aplicar estos criterios, el *dataset* final se compone de 2.937 partidos, información suficiente y representativa de la muestra.

Selección final de variables predictoras

El siguiente paso que se realizó fue definir el conjunto final de variables que se utilizarán en la predicción del modelo teniendo en cuenta que sólo se preservaría la información disponible antes de cada partido.

Para llevar a cabo el modelo se seleccionaron como variables predictoras aquellas explicadas en el punto anterior que se corresponden con el histórico construido. Así, se utilizaron variables que tiene en cuenta la forma reciente de los equipos medida a partir de los últimos cinco partidos, variables de rendimiento acumulado, variables según la condición de local o visitante; variables de contexto de la temporada en cuestión y variables derivadas de las diferencias entre ambos equipos.

Se conservaron en el conjunto de datos variables descriptivas del partido (nombres de los equipos, temporada, jornada, fecha) y las cuotas de partido de Bet365. No obstante, no se han incorporado en los modelos como variables predictoras.

La decisión de las variables predictoras corresponde a la idea de construir una versión del modelo basada en variables históricas sólidas sin incorporar un número excesivo de características desde el principio.

División del conjunto de datos

Una vez construido el conjunto de datos y seleccionadas las variables aleatorias, se procedió a su división en subconjunto de entrenamiento, validación y test

para poder llevar a cabo el entrenamiento, ajuste y evaluación de los modelos predictivos.

Dada la naturaleza temporal del problema en el que las variables predictoras han sido construidas a partir de información histórica previa a cada partido, se llevó a cabo una partición basada en el orden cronológico de los datos en lugar de una división aleatoria. De esta forma, se estaría llevando a cabo una simulación de un escenario realista en la que el modelo usa sólo información pasada para predecir eventos futuros.

De esta forma, los datos se ordenaron de forma cronológica según la fecha del encuentro y se dividieron en tres subconjuntos;

- Un conjunto de entrenamiento para ajustar los parámetros del modelo con los datos de las seis primeras temporadas (desde la campaña 2008-09 hasta la 2013-14).
- Un conjunto de validación para comparar los modelos y el ajuste de hiperparámetros con los datos de la temporada 2014-15.
- Un conjunto de *test* para la evaluación final del rendimiento del modelo seleccionado con los datos de la temporada 2015-16.

Mediante esta estrategia se garantiza que los modelos sean evaluados con datos temporalmente posteriores a los utilizados en el entrenamiento, proporcionando una estimación más realista de su capacidad de generalización.

5.2.3. Modelos predictivos empleados

Con el objetivo de abordar el problema de predicción de resultados en los partidos de fútbol, se planteó la evaluación comparativa de distintos modelos de clasificación, desde enfoques simples hasta modelos más complejos, permitiendo así analizar el impacto de la complejidad del modelo en el rendimiento predictivo.

Regresión logística multinomial

Como primer modelo predictivo, se empleó una regresión logística multinomial, adecuada para problemas de clasificación multiclase donde la variable dependiente es categórica. Este modelo permite estimar la probabilidad de cada una de las tres clases posibles (victoria local, empate o victoria visitante) en función de una combinación lineal de las variables predictoras (IBM).

Se optó por este modelo debido a su interpretabilidad y a su uso extendido en problemas de clasificación, lo que lo convierte en un buen punto de partida para la comparación con modelos más complejos.

En la primera prueba de este modelo predictivo se encontró un problema en los resultados, ya que detectaba casi todas las victorias locales mientras que no detectaba casi ningún empate. Este problema parecía venir de que nuestro *dataset* está desbalanceado.

Para solucionar el problema anterior, se implementó una variante del modelo incorporando ponderación de clases (class_weight = balanced) con el objetivo de mitigar el desbalanceo existente en la variable objetivo, donde la victoria local es la clase predominante. Con esta versión del modelo se mejoró la capacidad del mismo para predecir clases minoritarias y distribuyó mejor sus aciertos.

Random Forest

Como alternativa a los modelos lineales, se utilizó el algoritmo Random Forest, un método de aprendizaje basado en la construcción de múltiples árboles de decisión.

Un Random Forest o bosque aleatorio, desarrollado por Leo Breiman y Adele Cutler, combina el output de múltiples árboles de decisión para llegar a un único resultado y puede manejar tanto problemas de clasificación (como es el caso de este TFM) como de regresión (IBM).

Este tipo de modelo permite capturar relaciones no lineales entre las variables y es robusto frente a ruido en los datos.

Se evaluaron diferentes configuraciones del modelo con el objetivo de analizar el impacto de la regularización y del tratamiento del desbalanceo de clases:

- Un modelo estándar sin restricciones específicas que volvió a presentar el problema del desbalanceo de clases que vimos en la regresión logística multinomial.
- Un modelo regularizado mediante la limitación de parámetros como la profundidad de los árboles (se limitó a 10) y el número mínimo de muestras por hoja (concretamente 5), con el objetivo de reducir el sobreajuste.
- Un modelo regularizado con ponderación de clases (class_weight = balanced), con el fin de mejorar el rendimiento en clases minoritarias.

Esta comparativa permitió identificar la configuración más adecuada en términos de equilibrio entre capacidad predictiva y generalización. La configuración final elegida fue la del modelo Random Forest balanceado tras comparar una serie de métricas que serán explicadas en los siguientes puntos del TFM.

XGBoost

El último modelo evaluado de forma complementaria fue uno basado en técnicas de *gradient boosting*, concretamente *XGBoost*, con el objetivo de analizar si modelos más complejos podían mejorar el rendimiento predictivo.

XGBoost, desarrollado por Tianqi Chen, es una aplicación avanzada de la potenciación del gradiente con el mismo marco general, es decir, combina árboles de aprendizaje débiles en fuertes mediante la suma de residuos (IBM).

El *boosting* combina varios árboles débiles individuales para formar un aprendiz fuerte. Cada árbol de aprendizaje débil se entrena secuencialmente para corregir los errores cometidos por los modelos anteriores, y después de cientos de iteraciones, teóricamente los árboles débiles se convierten en fuertes permitiendo así un mayor poder predictivo en problemas de clasificación.

No obstante, su inclusión se planteó como un análisis adicional, priorizando en el trabajo modelos más interpretables y computacionalmente eficientes.

5.2.4. Métricas de evaluación

Para evaluar el rendimiento de los modelos predictivos se emplearon diversas métricas de clasificación, con el objetivo de obtener una visión completa del comportamiento de los modelos en un problema multiclase y con desbalanceo entre las categorías.

Dado que el objetivo del trabajo es predecir el resultado de un partido de fútbol en tres posibles clases (victoria local, empate o victoria visitante), no es suficiente con emplear una única métrica global, sino que resulta necesario analizar el rendimiento desde diferentes perspectivas.

- *Accuracy*

La *accuracy* o precisión global mide el porcentaje de predicciones correctas sobre el total de observaciones:

$$\text{Accuracy} = \frac{\text{Número de predicciones correctas}}{\text{Número total de predicciones}} \quad (1)$$

Esta métrica proporciona una visión general del rendimiento del modelo, pero presenta limitaciones en problemas desbalanceados, como el presente, donde una clase (victoria local) es más frecuente que las demás. En este contexto, un modelo puede obtener una buena *accuracy* simplemente prediciendo mayoritariamente la clase dominante, sin capturar adecuadamente las clases minoritarias.

- Matriz de confusión

La matriz de confusión es una herramienta de análisis visual del rendimiento del modelo que permite observar el número de predicciones correctas e incorrectas para cada clase (compara la clase predicha con respecto a la etiqueta real). De esta forma es capaz de identificar patrones de error como la tendencia a predecir de forma errónea victorias locales en lugar de empates o victorias visitantes.

Este análisis resulta especialmente útil para interpretar el comportamiento del modelo y detectar posibles sesgos en la predicción.

- *Precision*, *Recall* y F1-score

Para analizar el rendimiento de forma más detallada que con la *accuracy*, se utilizaron las métricas de *precision*, *recall* y *F1-score*, calculadas de forma independiente para cada una de las clases.

- La *precision* mide la proporción de predicciones correctas dentro de todas las predicciones realizadas para una clase determinada. Es decir, de los casos que clasifiqué como esta categoría, ¿cuántos eran verdad según su etiqueta? Esta es su fórmula:

  $$\text{Precision} = \frac{Verdaderos\ Positivos}{Verdaderos\ Positivos + Falsos\ Positivos} \quad (2)$$

- El *recall* (o sensibilidad) mide la capacidad del modelo para identificar correctamente todos los casos reales de una clase. Es decir, de todos los casos reales que había para esa categoría, ¿cuántos detecté? Esta es su fórmula:

  $$\text{Recall} = \frac{Verdaderos\ Positivos}{Verdaderos\ Positivos + Falsos\ Negativos} \quad (3)$$

- El *F1-score* combina ambas métricas como la media armónica entre *precision* y *recall*, proporcionando un equilibrio entre ambas. Es una métrica muy útil en *datasets* desbalanceados pues se centra en el coste de clasificar erróneamente. Esta es su fórmula:

$$F1 = 2 * \frac{Precision*Recall}{Precision+Recall} \quad (4)$$

Estas métricas permiten analizar el comportamiento del modelo en cada tipo de resultado (victoria local, empate o victoria visitante), siendo especialmente relevantes en el caso del empate, que representa la clase más difícil de predecir.

- Macro *F1-score*

Dado el carácter multiclase y el desbalanceo del problema, se utilizó el Macro *F1-score* como métrica principal de comparación entre modelos.

El Macro *F1* se calcula como la media aritmética del *F1-score* de cada clase, otorgando el mismo peso a todas ellas independientemente de su frecuencia:

$$\text{Macro F1} = \frac{F1HomeWin+F1Draw+F1AwayWin}{3} \quad (5)$$

Esta métrica resulta especialmente adecuada en este contexto, ya que penaliza a los modelos que presentan un buen rendimiento únicamente en la clase mayoritaria y permite evaluar de forma equilibrada la capacidad del modelo para predecir todas las clases.

- Implementación de las métricas

Todas las métricas descritas se calcularon utilizando la librería *scikit-learn* en *Python*. Para facilitar la evaluación de los distintos modelos, se implementó una función específica que calcula y muestra de forma conjunta la *accuracy*, el Macro *F1-score*, el informe de clasificación (*classification report*) y la matriz de confusión.

Esta función permitió estandarizar el proceso de evaluación y facilitar la comparación entre modelos en las distintas fases del experimento.

- Dificultad inherente del problema: el empate

Cabe destacar que la predicción de resultados en fútbol presenta una dificultad adicional asociada a la naturaleza de la variable objetivo, especialmente en lo relativo a la clase correspondiente al empate.

A diferencia de otros problemas de clasificación binaria, el presente estudio aborda un problema multiclase en el que una de las categorías (empate) resulta significativamente más compleja de modelizar. Esto se debe, en primer lugar, a su menor frecuencia relativa dentro del conjunto de datos, lo que implica que los modelos disponen de menos ejemplos para aprender patrones asociados a dicha clase.

Además, el empate en fútbol suele ser el resultado de situaciones altamente equilibradas entre ambos equipos, donde pequeñas variaciones o eventos puntuales pueden alterar el marcador final. Esta característica introduce un alto grado de incertidumbre y dificulta la identificación de patrones claros en los datos históricos.

Desde el punto de vista predictivo, esto se traduce en una tendencia de los modelos a favorecer las clases mayoritarias (especialmente la victoria local), reduciendo su capacidad para detectar correctamente los empates. Por este motivo, métricas como el Macro *F1-score* adquieren especial relevancia en este contexto, ya que permiten evaluar de forma equilibrada el rendimiento del modelo en todas las clases, penalizando aquellos casos en los que el modelo presenta un bajo desempeño en la predicción del empate.

5.2.5. Resultados experimentales

En este apartado se presentan los resultados obtenidos tras el entrenamiento y evaluación de los distintos modelos predictivos desarrollados en este trabajo. En primer lugar, se realiza una evaluación en el conjunto de validación con el objetivo de comparar los modelos y seleccionar la mejor alternativa. Posteriormente, el modelo elegido se evalúa en el conjunto *test* y se lleva a cabo un análisis de los resultados de la predicción.

Resultados en el conjunto de validación

Con el objetivo de comparar el rendimiento de los distintos modelos propuestos, se evaluaron todos ellos sobre el conjunto de validación utilizando las métricas descritas anteriormente. En la Tabla 1 se muestran los resultados obtenidos en términos de *accuracy* y Macro *F1-score*.

Tabla 1

Resultados experimentales de Accuracy y Macro F1-score de los diferentes modelos en el conjunto de validación

Modelo	***Accuracy***	***Macro F1***
Regresión logística multinomial	54,89%	44,50%
Regresión logística multinomial balanceada	45,92%	44,23%
Random Forest	54,89%	42,06%
Random Forest regularizado	54,62%	38,77%
Random Forest balanceado	52,45%	49,25%
XGBoost	47,28%	39,41%

Nota: Elaboración propia (2026)

A partir de estos resultados se puede observar que en términos de *accuracy*, varios modelos presentan resultados similares, especialmente la regresión logística y el Random Forest estándar quienes, a su vez, presentan los resultados más altos de esta métrica frente al resto de modelos. No obstante, al ser un problema de clases desbalanceadas, esta métrica no es suficiente para evaluar por sí sola el rendimiento de los modelos.

Al analizar el Macro *F1-score* que equilibra el rendimiento entre clases, se observa que el modelo *Random Forest* con ponderación de clases (*RF balanced*)

presenta el mejor rendimiento global (49,25%) superando a su siguiente competidor, la regresión logística multinomial de forma abultada (44,5%).

Estas métricas permiten una primera comparación global, pero para comprender en mayor profundidad el comportamiento de los modelos, resulta necesario analizar el rendimiento por clase. En la Tabla 2 se muestran los valores de *F1-score* para cada una de las clases.

Tabla 2.

Resultados experimentales de F1 Score a nivel de etiqueta de los diferentes modelos en el conjunto de validación

Modelo	***F1-Score AwayWin***	***F1-Score Draw***	***F1-Score HomeWin***
Regresión logística multinomial	46%	18%	69%
Regresión logística multinomial balanceada	40%	33%	60%
Random Forest	48%	10%	68%
Random Forest regularizado	49%	0%	67%
Random Forest balanceado	47%	34%	66%
XGBoost	40%	17%	61%

Nota: Elaboración propia (2026).

El análisis de estas métricas permite extraer conclusiones claves. En primer lugar, todos los modelos presentan un buen rendimiento en la predicción de la victoria local, con valores de F1 por encima del 60%, lo cual refleja la mayor frecuencia de esta clase, así como la facilidad de los modelos para predecirla.

No obstante, la principal dificultad del problema se encuentra en la predicción del empate. Los modelos no balanceados presentan un rendimiento inferior al 20% en todos los casos, siendo especialmente llamativo el caso del Random Forest regularizado con un 0%, lo que indica una tendencia a ignorar esta clase en favor de la mayoritaria.

La regresión logística multinomial balanceada mejora la predicción del empate frente a su versión estándar (33% vs 18%) a costa de una reducción del rendimiento global del problema.

Por su parte, el modelo *Random Forest* balanceado es quien consigue el mejor equilibrio entre las tres clases y consigue la mejor predicción del empate frente al resto de modelos evaluados (34%). Su buen rendimiento en las otras dos clases le permite tener el mejor Macro *F1-score* global.

Por tanto, la introducción de ponderación de clases permite al modelo capturar mejor los patrones asociados a las clases minoritarias sin deteriorar de forma significativa el rendimiento global del mismo.

Selección del modelo final

La selección del modelo final se realizó considerando el equilibrio entre el rendimiento global y la capacidad de predicción en todas las clases, dando especial importancia al Macro *F1-score* y al comportamiento en la clase minoritaria.

Aunque modelos como la regresión logística multinomial y el *Random Forest* estándar presentan la mayor *accuracy*, su bajo rendimiento en la predicción del empate evidencia un sesgo hacia la clase mayoritaria.

El modelo *Random Forest* balanceado presenta el mejor rendimiento global en Macro *F1-score*, así como el mejor comportamiento en la predicción de la clase

minoritaria sin que el rendimiento en las otras clases se vea excesivamente afectado.

Por tanto, se selecciona este último como modelo final en el que se evaluará el conjunto test, al ofrecer el mejor equilibrio entre capacidad predictiva y equilibrio de clases.

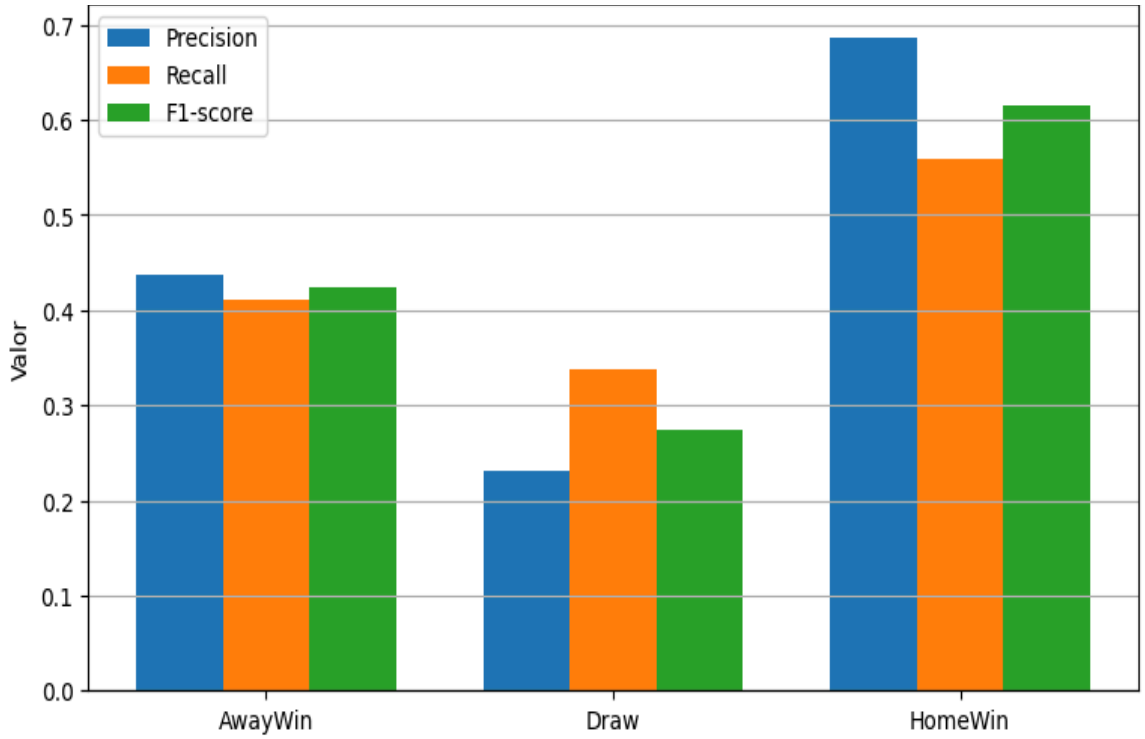
Resultados en el conjunto de test

Una vez seleccionado el modelo final, se evaluó su rendimiento en el conjunto de *test*.

Este rendimiento no disminuyó demasiado con respecto al modelo en validación, ya que el *accuracy* fue del 46,615 y el Macro F1 del 43,79%.

Figura 1.

Métricas por clase - Random Forest balanced (Test).



Nota: En la Figura 1 se muestra una comparativa entre las métricas de *precision, recall* y *F1-score* para cada una de las clases etiquetadas del modelo. Elaboración propia (2026)

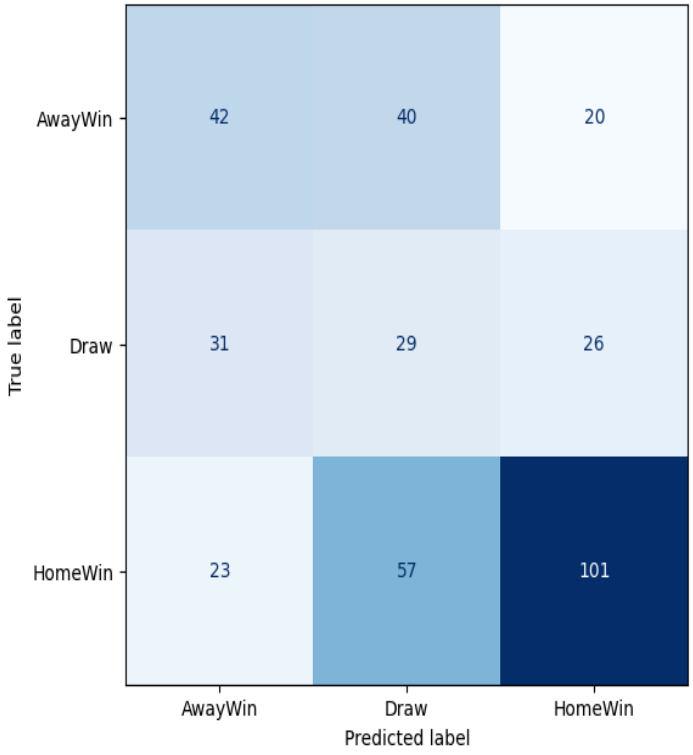
Se observa que el modelo presenta un comportamiento desigual entre clases, tal y como pasaba en los resultados de validación. En primer lugar, la clase *HomeWin* es la mejor predicha, alcanzando valores elevados tanto en *precision* (69%) como en *F1-score* (62%). Este resultado es consistente con el desbalanceo natural del *dataset*, donde la victoria local es la categoría más frecuente, así como con la conocida ventaja de jugar en casa en el fútbol profesional.

En segundo lugar, la clase *AwayWin* presenta un rendimiento intermedio, con un *F1-score* de 42%. El modelo es capaz de identificar una parte relevante de estas situaciones, aunque con menor precisión que en el caso de las victorias locales.

Por último, la clase *Draw* es la más difícil de predecir, con un *F1-score* de 27%. Aunque el *recall* (34%) indica que el modelo identifica algunos empates reales, la baja *precision* refleja una alta tasa de falsas predicciones de empate. Este comportamiento manifiesta la dificultad inherente del problema, ya que el empate es un resultado menos frecuente y más condicionado por eventos aleatorios del partido.

Figura 2.

Matriz de confusión - Random Forest balanced (Test).



Nota: La Figura 2 muestra la matriz de confusión que permite analizar de forma más detallada los aciertos y errores del modelo. Elaboración propia (2026)

En relación con el análisis de la misma, se puede observar que el modelo tiene una tendencia relevante a confundir victorias locales con empates (57 casos), lo que indica que el modelo detecta cierta proximidad entre ambos escenarios.

Para la clase *AwayWin*, el modelo acierta en 42 de los 102 casos, pero presenta confusiones significativas con empate (40 casos), lo que sugiere que las derrotas del equipo local no siempre se distinguen claramente de situaciones equilibradas.

La clase *Draw* vuelve a ser la más problemática. Solo 29 de los 86 empates se clasifican correctamente, mientras que una proporción considerable se asigna como victorias locales (26) o visitantes (31). Este patrón evidencia que el empate se sitúa en una zona intermedia entre ambas clases, dificultando su separación por parte del modelo.

En términos generales, la matriz de confusión refleja que el modelo tiende a inclinar sus predicciones hacia las clases mayoritarias (especialmente la victoria local), aunque mantiene cierta capacidad para identificar las demás categorías.

En conjunto, los resultados obtenidos muestran que el modelo es capaz de capturar patrones relevantes en los datos históricos, especialmente en la predicción de victorias locales. Sin embargo, la predicción de empates continúa siendo un desafío significativo, lo que coincide con la literatura existente sobre la alta incertidumbre y variabilidad del fútbol. Estos resultados no solo reflejan las limitaciones del modelo, sino también la complejidad inherente del problema, donde factores no observables y eventos aleatorios influyen de manera decisiva en el resultado final.

Análisis de los resultados

Estos resultados ponen de manifiesto varias características relevantes del problema de predicción de resultados en fútbol.

En primer lugar, se observa una dificultad en la predicción de la clase correspondiente al empate, lo que se traduce en valores más bajos de *recall, precision* y *F1-score* para esta categoría en todos los modelos evaluados. Este comportamiento es coherente con la naturaleza del problema, ya que los empates suelen producirse en situaciones altamente equilibradas y con un mayor componente de aleatoriedad.

Asimismo, los modelos tienden a predecir con mayor precisión la victoria local, lo que puede explicarse tanto por su mayor frecuencia en el *dataset* como por la existencia del efecto de ventaja de jugar en casa en el mundo del fútbol.

Por otro lado, los resultados obtenidos indican que el uso de modelos más complejos no garantiza necesariamente una mejora en el rendimiento

predictivo. En este caso, el modelo *Random Forest* balanceado ha demostrado ser más eficaz en rendimiento que modelos más avanzados como *XGBoost*.

Una posible explicación de este peor rendimiento es que *XGBoost*, al ser más sensible al ruido y requerir mayor volumen de datos para estabilizarse, se vio penalizado por el tamaño reducido del *dataset* (2.937 partidos). *Random Forest*, por su naturaleza de promediar múltiples árboles independientes, resultó más robusto en este escenario de datos limitados.

A continuación, se detalla una tabla resumen de los mejores modelos para cada objetivo según los resultados sobre el conjunto de validación.

Tabla 3

Resumen de mejores configuraciones por objetivo

Objetivo	**Mejor modelo**	***Métrica clave***	***Valor***
Precisión global	*Random Forest* estándar y regresión logística	Accuracy	54,89%
Equilibrio entre clases	*Random Forest* balanceado	Macro F1-score	49,25%
Predicción de empates	*Random Forest* balanceado	F1-Draw	34%

Predicción victoria local	Regresión logística	F1-HomeWin	69%
Predicción victoria visitante	*Random Forest* balanceado **El Random Forest regularizado sacrifica completamente la predicción de empates (0%) para maximizar la detección de victorias visitantes*	F1-AwayWin	47%

Nota: Elaboración propia (2026)

En conjunto, estos resultados reflejan tanto la utilidad de las variables históricas construidas como las limitaciones inherentes al problema, proporcionando una base sólida para la interpretación de los modelos y su aplicación en contextos reales.

5.3. Propuesta teórica de una herramienta de visualización táctica interactiva

Como complemento al motor predictivo desarrollado en el presente trabajo, se plantea una propuesta teórica orientada a la integración de herramientas de visualización táctica interactiva en el ámbito del análisis de datos aplicado al fútbol. De esta forma se pretende justificar la relevancia de la visualización y describir de forma teórica una herramienta capaz de combinar información histórica, análisis táctico y predicciones generadas mediante el motor predictivo de *Machine Learning* previamente desarrollado.

5.3.1. Justificación de la visualización de los datos en el fútbol

En este apartado se desarrolla una propuesta teórica para la implementación de una herramienta de visualización táctica interactiva que combine una

representación de los datos históricos de los clubes, así como las estadísticas y predicciones del modelo de *Machine Learning*. Esta propuesta se formula como una línea que permitiría trasladar los resultados del motor predictivo a un entorno más útil y visual para los perfiles deportivos no técnicos.

Tal y como define IBM en su web oficial, la visualización de datos es “la representación de datos mediante el uso de gráficos comunes, como diagramas, gráficas, infografías e incluso animaciones”. Además, reflejan la importancia de esta práctica como un “paso crítico en el proceso de la ciencia de datos”, reflejando su importancia para que la información de los datos se pueda transmitir de forma más efectiva a los responsables de la toma de decisiones.

La necesidad de incorporar visualización en proyectos de analítica en el mundo del deporte se justifica por la naturaleza de los propios datos, ya que no sólo existe información numérica como las variables utilizadas en este TFM, sino que también hay datos de componentes espaciales, temporales y contextuales. Entregar una tabla con millones de filas y columnas no sería útil para un deportista y, en este sentido, la literatura señala que la visualización de datos deportivos permite explorar, analizar y comunicar patrones de juego de forma más accesible y comprensible para los perfiles no técnicos, tal y como señalan Perin, C. et al. (2018).

En el caso del fútbol, diversos trabajos e investigaciones han mostrado la gran utilidad de las interfaces visuales para apoyar el análisis táctico. Por ejemplo, SoccerStories se diseñó como una herramienta para ayudar a analistas a explorar datos de fútbol y comunicar hallazgos relevantes. Según Perin, C et. Al. (2013), el análisis cuantitativo no ofrece una visión completa del juego para los analistas, sino que es necesario contar con otros aspectos como el contexto, las posiciones de los jugadores y las fases de acción, las cuales se representan en la interfaz general de su herramienta.

De forma similar, Stein et al. (2015) propusieron un sistema de análisis visual interactivo para poder identificar patrones colectivos y situaciones relevantes en un partido de fútbol.

Santo et.al. (2018) presentaron un prototipo de software interactivo diseñado para analizar visualmente el comportamiento táctico y el rendimiento en el fútbol profesional. Estos autores reflejan en su trabajo que en los equipos de élite se utiliza software científico genérico como Matlab para analizar las cantidades masivas de datos, lo cual hace que el proceso sea lento e ineficiente.

De esta forma, proponen un panel visual interactivo que explore simultáneamente datos espaciotemporales e interacciones multivariables en una interfaz con tres áreas: jugador virtual (recreación animada en 2D del partido en tiempo real), área de análisis individual (gráficos de posición y velocidad) y área de análisis grupal (gráficos que muestran la evolución de métricas colectivas como el centro, la dispersión y la sincronía del equipo).

Por último, tal y como mencionó Sánchez, R. (2026) en la entrevista realizada, actualmente en el fútbol profesional el análisis de datos se enfoca más en la interpretación del pasado que en la predicción, por lo que combinar ambas técnicas en una herramienta de visualización interactiva podría ser un enfoque diferencial para un club de fútbol.

A partir de estas referencias y testimonios, la propuesta teórica del presente trabajo consiste en el diseño de una interfaz que combine tres tipos de información: datos históricos de rendimiento, predicciones prepartido y visualizaciones tácticas. Esta herramienta permitiría a los entrenadores y analistas seleccionar un partido o equipo concreto (no sólo el suyo propio) y mostrar indicadores como la forma reciente de los equipos, diferencia de goles, rendimientos como local o visitante y probabilidades estimadas de sus próximos partidos.

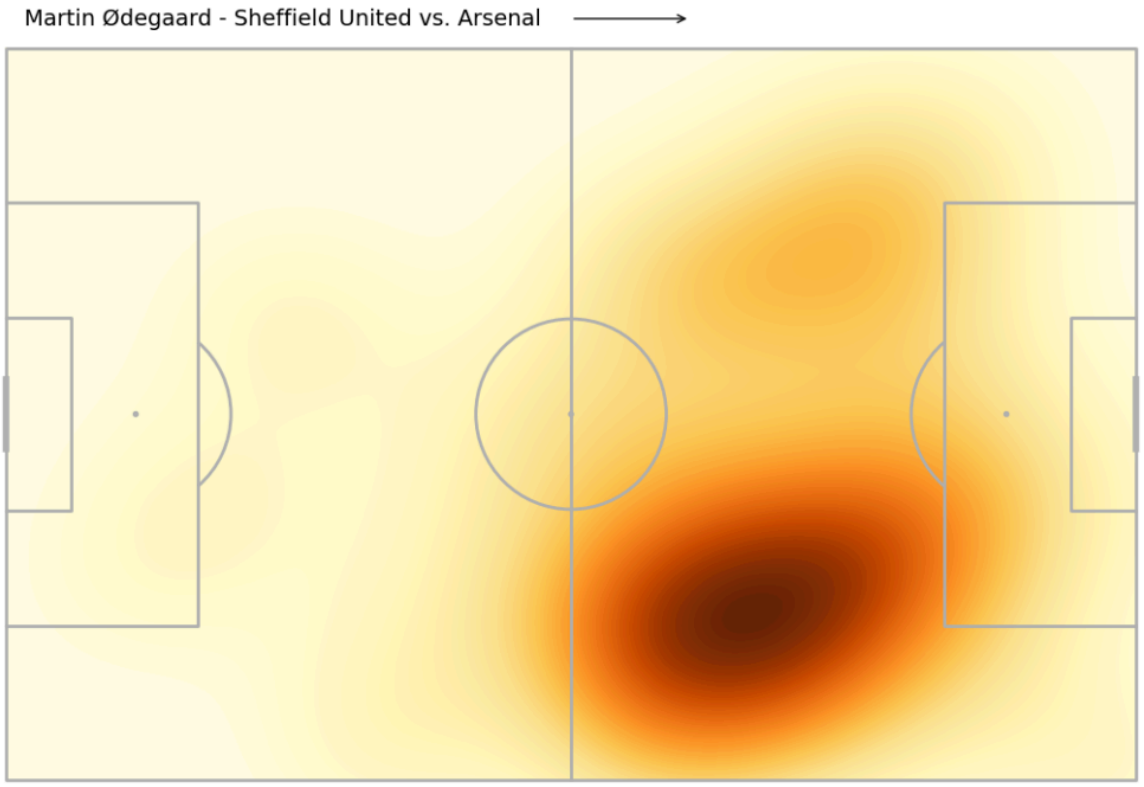
Desde el punto de vista visual, la herramienta podría incorporar gráficos comparativos entre equipos, evolución temporal de métricas, visualizaciones de probabilidades del modelo y representaciones espaciales sobre el campo, como mapas de calor, diagramas de dispersión o mapas de tiros, para lo cual sería necesario la integración de datos de eventos más detallados.

Librerías como *mplsoccer* permiten generar gráficos específicos de fútbol en *Python*, herramienta utilizada en el presente trabajo. En esta librería se puede graficar estadios de fútbol, gráficos de radar, gráficos de relieve para mostrar cambios a lo largo del tiempo, mapas de calor y diagramas de dispersión, entre otras. También es posible cargar datos abiertos de *StatsBomb*, *dataset* con más variables detalladas de eventos de partidos.

A continuación, se muestra un ejemplo de un mapa de calor elaborado mediante la librería *mplsoccer* en *Python*.

Figura 3.

Mapa de calor de Martin Odegaard – Sheffield United vs. Arsenal - Python. (Carpio, G)



Carpio, G. (2024). *Martin Odegaard – Sheffield United vs. Arsenal*. Fútbol con Datos. https://futbolcondatos.com/mapas-de-calor-con-python/

La aportación de esta propuesta no sólo es estética, sino funcional. Un resultado predictivo que no sea interpretable no ayuda al entrenador o analista en la toma de decisiones. Con esta herramienta se traducirían resultados técnicos a una información comprensible por un usuario no especializado en la ciencia de datos. Mientras que el modelo permite estimar las probabilidades, la visualización interactiva permite contextualizarlas, explicar sus posibles causas y comunicar la información de manera clara y sencilla.

5.3.2. Objetivos de la herramienta propuesta

El objetivo principal de la herramienta de visualización táctica interactiva es facilitar la interpretación y la comunicación de los resultados generados por el motor predictivo desarrollado combinados con información estadística e

histórica del club y de los jugadores mediante una interfaz visual interactiva orientada al usuario final.

Dado que un modelo predictivo no es suficiente para tomar decisiones dentro de un club, es necesario que los datos estadísticos y probabilidades generadas por el modelo se transformen en información visual comprensible y útil que pueda ser utilizada y analizada por entrenadores, analistas y departamentos de *scouting*.

El objetivo es que la interfaz sea capaz de mostrar información histórica, estadística y predictiva de equipos concretos y enfrentamientos entre equipos. Para ello, integraría datos históricos de rendimiento de los equipos, variables estadísticas derivadas del modelo, comparativas entre los equipos, predicciones prepartido (y probabilidad de confianza) y otros elementos visuales orientadas al análisis táctico.

Por tanto, el objetivo de la herramienta propuesta no sería únicamente mejorar la representación visual de los datos de forma estética, sino servir como una herramienta de trabajo útil que comunique predicciones, datos históricos y estadísticas de forma clara y sencilla a usuarios no técnicos como el cuerpo técnico, el departamento de *scouting* o los analistas.

5.3.3. Diseño conceptual de la herramienta

A partir de la propuesta planteada en los puntos anteriores, se propone el diseño conceptual de una herramienta de visualización táctica interactiva orientada al análisis de datos, comunicación de predicciones y apoyo en la toma de decisiones en el fútbol profesional.

La propuesta seguiría un enfoque de *dashboard* interactivo dividido en diferentes módulos, de manera que el usuario pudiera explorar de forma intuitiva diferentes datos e información según sus intenciones. A pesar de que

este sea un diseño conceptual general, a la hora de llevarlo a cabo en un club profesional, el equipo de ciencia de datos debería consultar con entrenadores y analistas las necesidades e intenciones de visualización que tienen cada uno de ellos. De esta forma, la herramienta podría adaptarse a sus requerimientos y aumentaría la probabilidad de que fuese un éxito si consiguiese resolver parte de sus problemas del día a día.

Se propone una estructura en cuatro áreas principales.

En primer lugar, una sección que sería el panel de navegación donde el usuario podría seleccionar el partido o equipo que desea analizar. También, podrían incorporarse filtros relacionados con la *condición de local o visitante, los últimos partidos disputados, periodo temporal y métricas específicas*. De esta forma, se personaliza la experiencia del usuario en la interfaz según las necesidades del mismo.

Este sería un boceto diseñado de cómo podría quedar el panel de navegación inicial. Los equipos y el escudo que aparecen no son reales.

Figura 4.

Panel de navegación.



Nota: En la Figura 4 se muestra un diseño del panel de navegación. Este diseño ha sido creado con Inteligencia Artificial, concretamente con Nano Banana, a partir de mi propia descripción. Elaboración propia (2026)

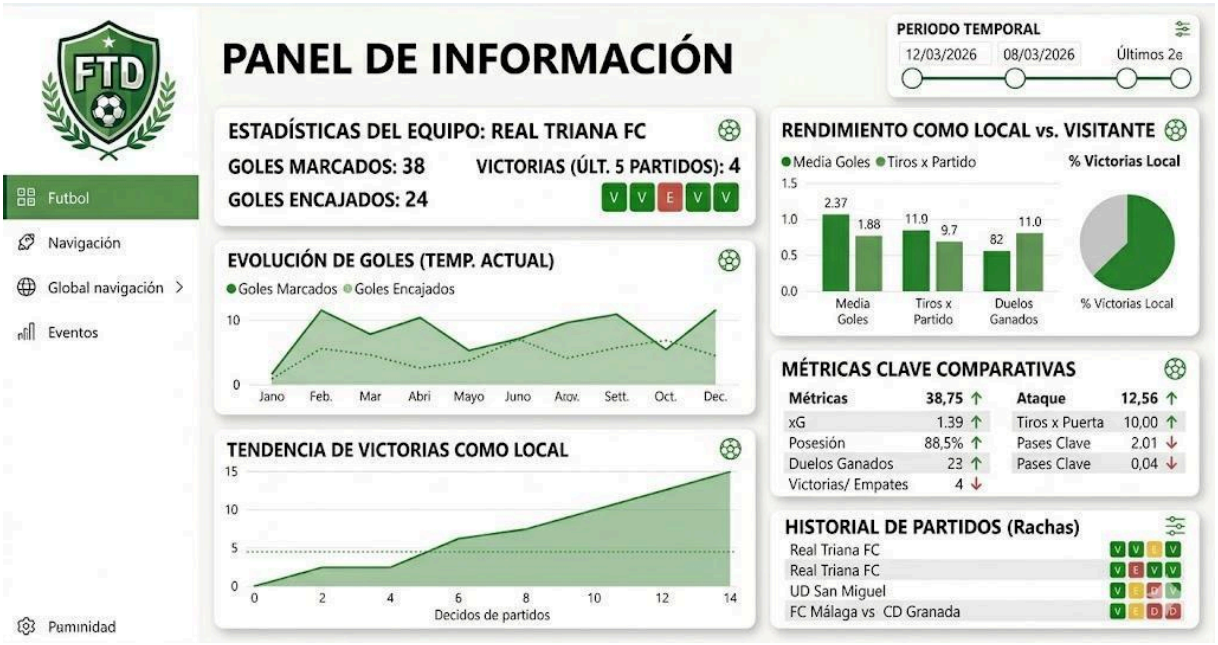
La segunda sección estaría dedicada a mostrar información histórica y estadística de ambos equipos de forma previa al partido. Para ello se incluirían gráficos y una serie de *KPIs* (es decir, indicadores claves de desempeño) como la forma reciente de los equipos en los últimos partidos (puntos obtenidos y victorias), media de goles marcados y encajados, o rendimiento como local o visitante, entre otros.

Utilizando variables como estas que son las que se han usado en el entrenamiento del modelo predictivo, se puede relacionar directamente la información histórica con la predicción generada por el modelo.

Este sería un boceto del segundo panel.

Figura 5.

Panel de información.



Nota: En la Figura 5 se muestra un diseño del panel de información. Este diseño ha sido creado con Inteligencia Artificial, concretamente con Nano Banana, a partir de mi propia descripción. Elaboración propia (2026)

El tercer módulo sería el panel predictivo donde se representan los resultados generados por el motor de *Machine Learning* previamente desarrollado. A pesar de que en este TFM hemos elegido un modelo, en este tipo de herramientas podríamos tener los dos mejores modelos en producción y comparar sus predicciones. También podrían mostrarse las probabilidades estimadas de victoria local, empate o victoria visitante; el nivel de confianza del modelo al dar la predicción y las variables más influyentes en la misma.

De hecho, este módulo podría complementarse en el futuro con técnicas de interpretabilidad de modelos como *SHAP* o *LIME* de forma que ayude a los entrenadores a entender por qué el modelo genera ciertas predicciones.

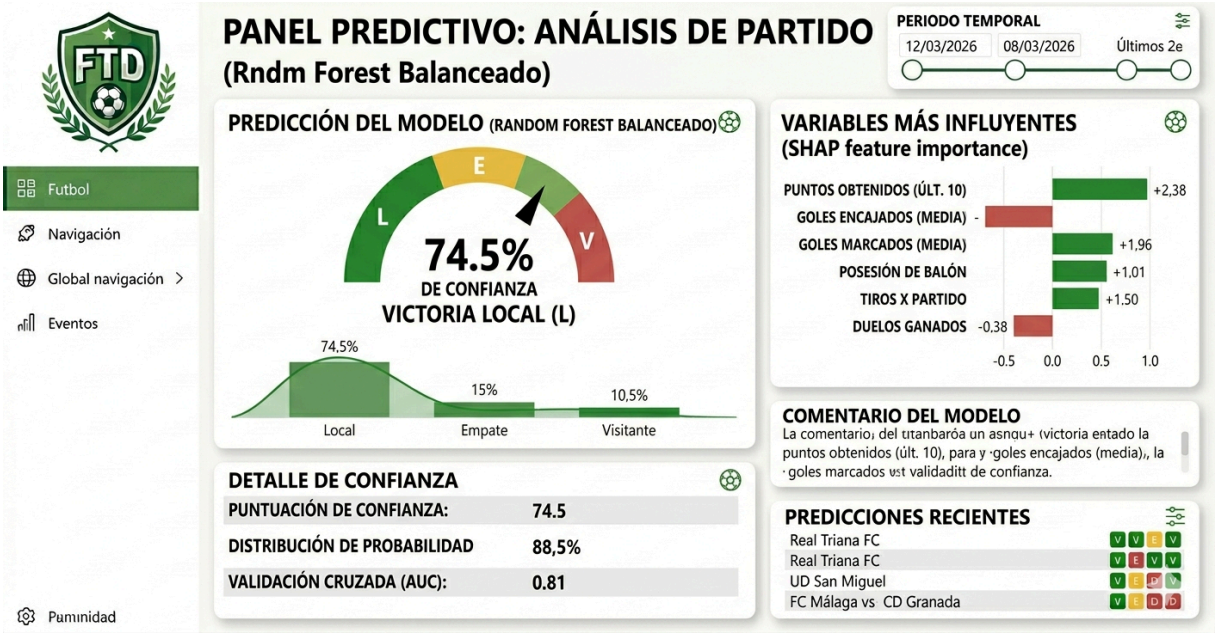
Según la web de Qlik, los valores *SHAP* representan cuánto contribuye cada característica al valor predicho; mientras que el resultado de *LIME* representa la contribución de cada característica a una predicción para una sola muestra (Ribeiro, M. et al., 2016), es decir, se trata de una explicación local.

A modo de ejemplo de aplicación, el panel predictivo (Figura 6) mostraría para un próximo partido, por ejemplo, Real Triana vs. UD San Miguel, las probabilidades estimadas por el modelo *Random Forest* balanceado: victoria local (74,5%), empate (15%) y victoria visitante (10,5%). Estas probabilidades se calcularían en tiempo real a partir de las variables históricas prepartido de ambos equipos (puntos obtenidos, media de goles encajados, media de goles marcados, etc.). El usuario podría visualizar qué variables han influido más en la predicción, facilitando así la interpretación del modelo.

Este sería la propuesta de diseño para el tercer módulo.

Figura 6.

Panel predictivo.



Nota: En la Figura 6 se muestra un diseño del panel predictivo. Este diseño ha sido creado con Inteligencia Artificial, concretamente con Nano Banana, a partir de mi propia descripción. Elaboración propia (2026)

La última sección, sería un panel táctico y espacial en el que se representaría de forma visual el comportamiento táctico de los equipos mediante datos espaciales y eventos del partido. Para llevar a cabo este panel, será necesario integrar *datasets* con variables que representen eventos más detallados de los partidos como pases, tiros, recuperaciones o secuencias ofensivas. De esta forma, se crearían visualizaciones como mapas de calor, diagramas espaciales o mapas de tiros.

Esta sería la propuesta de diseño del cuarto y último módulo.

Figura 7.

Panel táctico y espacial.



Nota: En la Figura 7 se muestra un diseño del panel táctico y espacial. Este diseño ha sido creado con Inteligencia Artificial, concretamente con Nano Banana, a partir de mi propia descripción. Elaboración propia (2026)

Aunque la herramienta no se implementa dentro del alcance de este trabajo, su desarrollo sería técnicamente viable mediante tecnologías actuales del ecosistema *Python*, así como otras herramientas orientadas a la visualización interactiva. Entre estas potenciales herramientas destacan:

- *mplsoccer*, mencionado anteriormente, es una librería de *Python* especializada en gráficos tácticos y representaciones espaciales de fútbol.
- *Streamlit* se trata de una herramienta con la que se pueden convertir *scripts* de datos en aplicaciones web interactivas en usando *Python*.
- *Plotly Dash* se trata de un *framework* de código abierto en *Python* para crear aplicaciones web analíticas y *dashboards*.
- *Power BI* se trata de una herramienta de *Business Intelligence* (Inteligencia de Negocios) que permite llevar a cabo *dashboards*, visualizaciones y análisis de datos. Desarrollada por *Microsoft*, es compatible con visualizaciones en *Python* y muy fácil de usar para el usuario, especialmente útil en empresas que ya tienen el entorno *Microsoft.*

La elección de la herramienta dependerá de las posibilidades y necesidades específicas del club. Estas tecnologías también podrían combinarse de manera que se desarrollase una plataforma interactiva capaz de integrar modelos predictivos, análisis estadístico y visualización táctica en un único entorno.

En contextos profesionales, esta herramienta podría emplearse para análisis previo de rivales, preparación táctica de partidos, apoyo al *scouting* y evaluación del rendimiento del equipo.

Por tanto, el diseño propuesto se trata de una posible evolución aplicada del motor predictivo desarrollado en este TFM, gracias al cual logramos conectar los modelos de *Machine Learning* y analítica avanzada con las necesidades de

interpretación y la toma de decisiones dentro de la industria del fútbol profesional.

6. Conclusiones

6.1. Cumplimiento de los objetivos

Se ha alcanzado el objetivo general del presente trabajo de crear un motor predictivo de resultados basado en los partidos de la liga de fútbol española. En cuanto a los objetivos específicos: (1) se ha analizado el estado del arte de las técnicas utilizadas en predicción de resultados en la industria del fútbol, (2) se han identificado patrones complejos para modelar el rendimiento de los equipos mediante variables históricas prepartido, (3) se ha construido un *dataset* estructurado basado en el *European Soccer Database* filtrado por LaLiga española, (4) se han implementado y comparado los modelos de clasificación propuestos y (5) se ha planteado la herramienta de visualización táctica de forma teórica.

El objetivo general del presente Trabajo de Fin de Máster consistía en crear un motor predictivo de resultados basado en los partidos de la liga de fútbol española. Dicho objetivo se ha alcanzado mediante el desarrollo de un pipeline completo que incluye la obtención, preparación y transformación de datos históricos de la liga española, la construcción de variables predictoras prepartido, la división de datos en conjuntos de entrenamiento, validación y *test*; la implementación y comparación de distintos modelos de clasificación supervisada, y la elección del modelo con mejor rendimiento para nuestro caso de uso y objetivo, así como su evaluación para el conjunto *test*.

Este motor predictivo se trata de una base muy potente que se mejorará gradualmente con un mayor volumen de datos y añadiendo otras variables que pudieran mejorar el rendimiento del modelo.

En relación con los objetivos específicos, en primer lugar, se ha analizado el estado del arte sobre la predicción de resultados en fútbol, revisando enfoques estadísticos tradicionales, modelos de rating, técnicas de aprendizaje automático y el uso actual de datos en clubes profesionales, incluyendo una entrevista a un profesional del sector deportivo en el área de datos.

En segundo lugar, se han identificado y construido patrones históricos relevantes para modelar el rendimiento de los equipos. Para ello, se generaron variables basadas en la forma reciente, el rendimiento acumulado, el comportamiento local/visitante, los goles obtenidos y el contexto competitivo de la temporada, todas ellas calculadas únicamente con información previa al partido.

En tercer lugar, se ha desarrollado un conjunto de datos estructurado a partir del *European Soccer Database*, filtrado para la liga española. Este *dataset* final incorpora variables explicativas derivadas del rendimiento histórico de los equipos y constituye la base analítica empleada para el entrenamiento de los modelos.

En cuarto lugar, se han implementado y comparado distintos modelos de clasificación, concretamente regresión logística multinomial, *Random Forest* y *XGBoost*. La comparación permitió evaluar el comportamiento de modelos interpretables frente a modelos no lineales, seleccionando finalmente el enfoque con mejor equilibrio entre clases, el modelo *Random Forest* balanceado. El motivo principal de la elección de este modelo fue que tenía el mejor rendimiento global en Macro *F1-score*, así como el mejor comportamiento en la predicción de la clase minoritaria (empate) sin que el rendimiento en las otras clases se vea excesivamente afectado.

Por último, se ha planteado de forma teórica la incorporación de herramientas de visualización táctica interactiva. Este objetivo se ha definido como una línea

teórica orientada a mejorar la interpretación y aplicación de los modelos predictivos para los profesionales del sector futbolístico combinada con la visualización de datos históricos y estadísticos de los clubes de fútbol.

En conjunto, puede afirmarse que los objetivos planteados inicialmente han sido cumplidos, tanto en la dimensión teórica como en la dimensión práctica del proyecto.

6.2. Reflexión y aportaciones

La principal aportación de este trabajo no reside sólo en el desarrollo e implementación de modelos de *Machine Learning* aplicados a los resultados de fútbol, sino en la metodología de construcción de variables históricas prepartidos con el fin de representar el estado competitivo de los equipos antes de cada encuentro y de forma histórica.

Uno de los principales retos era transformar los datos históricos de resultados en un conjunto de variables útil para el aprendizaje automático y coherente desde el punto de vista temporal. Para lograrlo, se diseñó un proceso de ingeniería de variables basado en información disponible antes de cada partido, sin mezclar en ningún caso datos futuros que pudiesen provocar *data leakage* (es decir, problemas de fuga de información).

La construcción de métricas relacionadas con la forma reciente de los equipos, el rendimiento acumulado, el comportamiento como local o visitante, el rendimiento global histórico y el contexto competitivo de la temporada, entre otros, permitió modelar patrones históricos complejos asociados al rendimiento de cada equipo. Esta fase es una de las aportaciones más relevantes del proyecto, ya que la calidad y la representatividad de las variables condiciona el rendimiento de los modelos predictivos.

Otra aportación importante de este trabajo ha sido la comparación entre diferentes modelos de *Machine Learning* de clasificación aplicados a la predicción de resultados. Concretamente, se desarrollaron y evaluaron modelos de regresión logística multinomial, *Random Forest* y *XGBoost*, pudiendo comparar modelos más interpretables frente a modelos basados en árboles de decisión.

Los resultados obtenidos muestran que el modelo con mejor equilibrio global entre las tres clases (victoria local, empate o victoria visitante) fue el *Random Forest* balanceado, consiguiendo un Macro *F1-score* de 49,25%. Este modelo consiguió mejorar la capacidad predictiva sobre el empate, la clase más difícil de predecir, sin afectar demasiado al rendimiento en las otras dos etiquetas.

La regresión logística multinomial mostró un comportamiento más elevado en términos de *accuracy*, pero tendía a favorecer a la clase mayoritaria (victoria local). *XGBoost* no consiguió superar el rendimiento de *Random Forest* balanceado y también tendió a favorecer a la clase mayoritaria.

Los resultados permiten llevar a cabo una reflexión sobre la complejidad inherente en la predicción de resultados de fútbol. Tanto en validación como en el conjunto test, el empate fue la clase más difícil de predecir en todos los modelos implementados. Este comportamiento coincide con los trabajos revisados en el estado del arte y confirma que el fútbol tiene un alto componente estocástico donde el resultado puede verse influido por situaciones impredecibles como podría ser un error arbitral, una tarjeta roja o la concesión de un penalti en los últimos minutos del encuentro.

Por ´último, este trabajo aporta un diseño conceptual de una herramienta de visualización táctica interactiva en los clubes de fútbol para poder transformar los resultados del motor predictivo, así como otros datos históricos y aspectos tácticos relevantes en información útil y relevante para perfiles no técnicos como entrenadores o analistas profesionales.

6.3. Autocrítica y limitaciones

El presente trabajo presenta una serie de limitaciones que deben ser consideradas para su correcta interpretación.

En primer lugar, el conjunto de datos se limita al periodo comprendido entre 2008 y 2016, lo que implica que el *dataset* está desactualizado y no refleja la evolución del fútbol profesional de la última década. Tal y como indican en *The PFSA*, el fútbol ha sido un deporte que ha ido evolucionando desde su creación en formación tradicional, roles de jugadores, estrategia y táctica; siendo la introducción de software para el análisis táctico uno de los mayores beneficios para los equipos para la preparación de los partidos.

Además de la antigüedad de los datos, existe un problema de generalización temporal: el modelo fue entrenado con un estilo de juego propio de la década 2008-2016. La evolución táctica del fútbol (mayor presión alta, uso de porteros futbolistas, etc.) podría haber alterado las relaciones estadísticas entre las variables predictoras y los resultados. Un modelo entrenado exclusivamente con datos pasados podría no capturar estas nuevas dinámicas, lo que penalizaría su rendimiento en temporadas actuales.

Por otra parte, las variables usadas en este trabajo se basan en información previa al partido, sin tener en cuenta otras variables como eventos detallados del partido que podrían ser de utilidad. Herbinet, C (2018) muestra otras variables relevantes que influyen para predecir resultados de fútbol mediante técnicas de *Machine Learning* como goles esperados, posesión del balón, tiros a puerta, faltas, córneres o centros, entre otras.

Asimismo, el problema de la predicción de resultados presenta el problema de la incertidumbre propia de la naturaleza del fútbol, así como el desbalanceo de clases con la dificultad añadida de la predicción del empate.

No se ha llevado a cabo una optimización exhaustiva de los hiperparámetros de los modelos propuestos ni la exploración de otras arquitecturas más complejas debido a la limitación de tiempo y viabilidad del proyecto.

Finalmente, cabe señalar que este motor predictivo se concibe como una herramienta de apoyo al análisis deportivo, no como un sustituto del criterio humano. No debe utilizarse con fines de apuestas deportivas ni para tomar decisiones automáticas sin supervisión de un analista. La incertidumbre inherente al fútbol hace imprescindible mantener la intervención humana en cualquier proceso de toma de decisiones basado en estas predicciones.

6.4. Futuras líneas de investigación

A partir de las limitaciones identificadas, se plantean una serie de líneas de trabajo futuro a seguir para poder mejorar los resultados obtenidos en el presente trabajo.

En primer lugar, se propone la incorporación de *datasets* más recientes y extensos sobre la liga española. Utilizar información de los últimos 10 años permitiría entrenar modelos con mayor volumen de partidos y evaluar su rendimiento en el contexto futbolístico actual, teniendo en cuenta la evolución constante del fútbol profesional tal y como se señala en *The PFSA*.

En segundo lugar, sería relevante la incorporación de datos detallados sobre los eventos del partido procedentes de repositorios especializados como *StatsBomb* de Open Data. Este tipo de *datasets* incluye información como tiros, pases, posesión, goles esperados o córneres. Este tipo de datos permitiría tener variables con información táctica y eventos del juego, tal y como propuso Herbinet, C en 2018.

Además, otra línea futura de investigación interesante sería integrar información procedente de casas de apuestas y comparar el rendimiento del

modelo antes y después de la inclusión de dichos datos. Las cuotas de apuestas representan estimaciones probabilísticas gracias a grandes volúmenes de información analizados.

Otra línea de mejora relevante sería la exploración de otras técnicas de modelado más avanzadas, especialmente si se consigue un volumen de datos superior como se ha propuesto. En este sentido, podrían explorarse arquitecturas de redes neuronales o enfoques híbridos.

Además, sería relevante la incorporación de técnicas de interpretabilidad de modelos, *SHAP* o *LIME*, mencionadas anteriormente. Su aportación sería especialmente relevante para analizar qué variables influyen en mayor medida sobre las predicciones, lo cual permitiría aumentar la confianza de entrenadores y analistas en las predicciones del modelo.

Por último, una de las líneas de desarrollo futuro más diferenciales del presente trabajo consiste en la implementación de herramientas de visualización táctica interactiva. Esta herramienta permitiría representar tanto los datos históricos como las predicciones generadas por los modelos en gráficos intuitivos enfocados en el usuario final.

De esta forma, la interfaz visual permitiría traducir la información histórica como ya se está haciendo combinada con la predictiva en conocimiento útil para profesionales de la industria como entrenadores o analistas.

En el presente trabajo sólo se ha expuesto de forma teórica la construcción de dicha herramienta de visualización de datos y predicciones, pero el desarrollo de la misma sería una de las áreas de futuro más interesantes del presente trabajo.

Por tanto, las futuras líneas de investigación propuestas permitirían mejorar el modelo propuesto y evolucionar desde un motor predictivo de resultados de fútbol hacia una solución de apoyo para la toma de decisiones de profesionales de la industria del fútbol.

7. Referencias bibliográficas

Al-Bustami, A. & Ghazal, Z. (2025). *From Players to Champions: A Generalizable Machine Learning Approach for Match Outcome Prediction with Insights from the FIFA World Cup*. (s. f.). https://arxiv.org/html/2505.01902v1

AlMulla, J., Islam, M. T., Al-Absi, H. R. H., & Alam, T. (2023). SoccerNet: A Gated Recurrent Unit-based model to predict soccer match winners. *PLoS ONE*, *18*(8), e0288933. https://doi.org/10.1371/journal.pone.0288933

Anfilets, S. & Bezobrazov, S. & Golovko, V. & Sachenko, A. (2020). Deep multilayer neural network for predicting the winner of football matches. (2020). https://www.researchgate.net/publication/342416626_DEEP_MULTILAYER_NEURAL_NETWORK_FOR_PREDICTING_THE_WINNER_OF_FOOTBALL_MATCHES

Bing predice los resultados de los partidos de las principales ligas europeas y la Champions League – Centro de noticias. (2016, 17 marzo). https://news.microsoft.com/es-es/2016/03/17/bing-predice-resultados-partidos-principales-ligas-europeas-champions-league-2/

Bunker, R & Yeung, C. & Fujii, K. (s.f.). *Machine Learning for Soccer Match Result Prediction* https://arxiv.org/abs/2403.07669

Bunker, R. P., & Thabtah, F. (2017). A machine learning framework for sport result prediction. Applied Computing And Informatics, 15(1), 27-33. https://doi.org/10.1016/j.aci.2017.09.005

Carpio, G. (2024). *Martin Odegaard – Sheffield United vs. Arsenal*. Fútbol con Datos. https://futbolcondatos.com/mapas-de-calor-con-python/

Comité Olímpico Internacional. (s.f.). *Fútbol*. Olympics.com. https://www.olympics.com/es/deportes/futbol/

Comprender la importancia de SHAP en el entrenamiento de experimentos | Qlik Cloud Ayuda. (s. f.). https://help.qlik.com/es-ES/cloud-services/Subsystems/Hub/Content/Sense_Hub/AutoML/shap-importance.htm

Constantinou, A. C., & Fenton, N. E. (2013). Determining the level of ability of football teams by dynamic ratings based on the relative discrepancies in scores between adversaries. *Journal Of Quantitative Analysis In Sports*, *9*(1), 37-50. https://doi.org/10.1515/jqas-2012-0036

De La Vega, R., Del Valle Díaz, S., Maldonado, A.F., & Moreno, A. (2008). Una nueva herramienta para la comprensión táctica en el fútbol. https://www.researchgate.net/publication/40619457_Una_nueva_herramienta_para_la_comprension_tactica_en_el_futbol

Diéguez, V. (2022, 28 marzo). Cadena SER. Cadena SER. https://cadenaser.com/2022/03/28/los-datos-aplicados-al-negocio-del-futbol-asi-funciona-el-brentford-el-equipo-de-david-raya/

Constantinou, A. C., Fenton, N. E., & Neil, M. (2013). Profiting from an inefficient association football gambling market: Prediction, risk and uncertainty using Bayesian networks. Knowledge-Based Systems, 50, 60-86. https://doi.org/10.1016/j.knosys.2013.05.008

Lasek, J., Szlávik, Z., & Bhulai, S. (2013). The predictive power of ranking systems in association football. International Journal Of Applied Pattern Recognition, 1(1), 27. https://doi.org/10.1504/ijapr.2013.052339

Dixon, M. J., & Coles, S. G. (1997). *Modelling association football scores and inefficiencies in the football betting market*. Applied Statistics, 46(2), 265–280.

El equipo formado gracias al big data que sueña con la Premier League - ESPN. (2020b, agosto

3). ESPNdeportes.com. https://espndeportes.espn.com/futbol/inglaterra/nota/_/id/7243299/el-equipo-formado-gracias-al-big-data-que-suena-con-la-premier-league

Estefanía. (2026, 10 marzo). Modelo predictivo para fútbol ¿Cuál es el más eficaz? *Sports Data Campus*. https://sportsdatacampus.com/el-mejor-modelo-predictivo-para-futbol/

F. Rodrigues & A. Pinto. (2022) *Prediction of football match results with machine learning*, Procedia Computer Science, vol. 204, pp. 463–470, 2022.

FBREF. (s.f.). https://fbref.com/en/

Football results, statistics & soccer betting odds data. (s. f.-b). https://www.football-data.co.uk/data.php

Fraile, F. (2023, 13 febrero). Brentford, el recolector de diamantes en base al «Big Data». Relevo. https://www.relevo.com/futbol/premier-league/brentford-recolector-diamantes-20230210141439-nt.html

Global football | FIFA Publications. (s. f.). FIFA Publications. https://publications.fifa.com/en/talent-development/global-football/

González, E. (2013, septiembre). *Explicabilidad de modelos de ML: LIME*. Medium. https://medium.com/latinxinai/explicabilidad-de-modelos-de-ml-lime-f9d0dceb5154

Google Cloud Platform. (s. f.). GitHub - GoogleCloudPlatform/ipython-soccer-predictions: Sample iPython notebook with soccer predictions. GitHub. https://github.com/GoogleCloudPlatform/ipython-soccer-predictions/

Hassard, P & Kerr, D. (2025). *Predicting Football Match Outcomes using Event Data and Machine Learning Algorithms* https://trainingground.guru/wp-content/uploads/2025/12/Predicting_Football_Match_Outcomes_Using_Event_Data_and_Machine_Learning_Algorithms.pdf

Herbinet, C. (2018). Predicting football results using machine learning techniques. *MEng thesis, Imperial College London*.

Hvattum, L. M., & Arntzen, H. (2010). Using ELO ratings for match result prediction in association football. Decision Support Systems, 48(3), 541–548.

IBM. (2025, 11). Visualización de datos. *IBM*. https://www.ibm.com/es-es/think/topics/data-visualization

IBM. (s.f.). ¿Qué es un bosque aleatorio? IBM. https://www.ibm.com/es-es/think/topics/random-forest

IBM. (s.f.). ¿Qué es XGBoost? IBM. https://www.ibm.com/es-es/think/topics/xgboost

Keskin, Kerim. (2025). A game theory approach to football predictions. Public Choice. 206. 241-261. 10.1007/s11127-025-01317-x.

López, B. (s. f.). Juegos: Introducción. Universidad Nacional Autónoma de México. https://www.economia.unam.mx/profesores/blopez/juegos-introducción.pdf

Luo, Y., Quan, T., & Cao, Y. (2025). Predicting football match outcomes: a multilayer perceptron neural network model based on technical statistics indicators of the FIFA world Cup. *Frontiers In Sports And Active Living*, *7*, 1705198. https://doi.org/10.3389/fspor.2025.1705198

Ma, J. (2025). Advancement in real time football analysis using fuzzy based decision-making of the WASPAS method. *Scientific Reports*, *15*(1), 34731. https://doi.org/10.1038/s41598-025-18432-w

Maher, M. J. (1982). Modelling association football scores. Statistica Neerlandica, 36(3):109–118.

Mathien, H. (2017). *European Soccer Database*. Kaggle. https://www.kaggle.com/datasets/hugomathien/soccer

Modelo ELO en fútbol para apuestas deportivas. (s. f.). https://pastisseriacarrio.cat/modelo-elo-para-apuestas-de-futbol-calculo-y-aplicacion-practica/

mplsoccer 1.6.1. (s. f.). https://pypi.org/project/mplsoccer/

Oliver, L. C. (2021, 13 diciembre). *Teoría de juegos*. https://recursoseducativos.unam.mx/handle/123456789/19461

Perin, C., Vuillemot, R., & Fekete, J. (2013). *SoccerStories: A Kick-off for Visual Soccer Analysis*. *IEEE Transactions On Visualization And Computer Graphics*, *19*(12), 2506-2515. https://doi.org/10.1109/tvcg.2013.192

Perin, C., Vuillemot, R., Stolper, C. D., Stasko, J. T., Wood, J., & Carpendale, S. (2018). *State of the Art of Sports Data Visualization*. *Computer Graphics Forum*, *37*(3), 663-686. https://doi.org/10.1111/cgf.13447

Pfsa. (2024, 3 febrero). *La evolución del fútbol: cómo ha cambiado el juego a lo largo de las décadas*. The PFSA. https://thepfsa.co.uk/es/the-evolution-of-football-how-the-game-has-changed-over-the-decades/

Predictive Analytics In Football: How Clubs Use Data To Scout Smarter - TFA. (2025, 11 diciembre). totalfootballanalysis.com. https://totalfootballanalysis.com/th

ought-analysis/predictive-analytics-in-football-how-clubs-use-data-to-scout-smarter

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016, 16 febrero). *«Why Should I Trust You?»: Explaining the Predictions of Any Classifier*. arXiv.org. https://arxiv.org/abs/1602.04938

Richter, F. (2025, 27 mayo). The Global Game of Football. *Statista Daily Data*. https://www.statista.com/chart/14329/global-interest-in-football/

Santos, A. B., Theron, R., Losada, A., Sampaio, J. E., & Lago-Peñas, C. (2018). Data-Driven Visual Performance Analysis in Soccer: An Exploratory Prototype. *Frontiers In Psychology*, *9*, 2416. https://doi.org/10.3389/fpsyg.2018.02416

Sarmento, H., Marcelino, R., Anguera, M. T., CampaniÇo, J., Matos, N., & LeitÃo, J. C. (2014). Match analysis in football: a systematic review. *Journal Of Sports Sciences*, *32*(20), 1831-1843. https://doi.org/10.1080/02640414.2014.898852

Song, Y., Sun, G., Wu, C., Pang, B., Zhao, W., & Zhou, R. (2024). Construction of 2022 Qatar World Cup match result prediction model and analysis of performance indicators. *Frontiers In Sports And Active Living*, 6, 1410632. https://doi.org/10.3389/fspor.2024.1410632

Statsbomb. (s. f.). *GitHub - statsbomb/open-data: Free football data from StatsBomb*. GitHub. https://github.com/statsbomb/open-data

Talent Development | FIFA publications. (2022). FIFA Publications. https://publications.fifa.com/

The FA (sitio web general): The Football Association. (s. f.). The FA. https://publications.fifa.com/es/annual-report-2022/tournaments-and-events/fifa-world-cup-quatar-2022/fifa-world-cup-qatar-2022-in-numbers/

Wesley. (2025, 25 agosto). The power of big data in transforming football analytics.
Sportmonks. https://www.sportmonks.com/blogs/the-power-of-big-data-in-transforming-football-analytics/